

应用数理统计

Ch5 回归分析

-----多元线性回归

2014年6月25日

多元线性回归的数学模型

设自变量 x_1, x_2, \dots, x_m 与因变量 y 之间，有下列关系

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \varepsilon$$

其中， $\beta_0, \beta_1, \dots, \beta_m$ 是常数， $\varepsilon \sim N(0, \sigma^2)$ 是表示误差的随机变量。

对 x_1, x_2, \dots, x_m, y 进行 n 次观测，得到一组观测值：

$$(x_{i1}, x_{i2}, \dots, x_{im}, y_i), \quad i = 1, 2, \dots, n$$

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \dots + \beta_m x_{1m} + \varepsilon_1 \\ \vdots \\ y_n = \beta_0 + \beta_1 x_{n1} + \dots + \beta_m x_{nm} + \varepsilon_n \end{cases}$$

$\varepsilon_i \sim N(0, \sigma^2)$, $i = 1, 2, \dots, n$, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 相互独立

为了简单起见，我们将它写成矩阵向量形式。

$$\text{令 } Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1m} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}, \quad e = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \cdots + \beta_m x_{1m} + \varepsilon_1 \\ \vdots \\ y_n = \beta_0 + \beta_1 x_{n1} + \cdots + \beta_m x_{nm} + \varepsilon_n \end{cases} \quad \Rightarrow \quad Y = X\beta + e, \quad e \sim N_n(\mathbf{0}, \sigma^2 I)$$

$$N_n(\mathbf{0}, \sigma^2 I) \text{ 表示 } n \text{ 元正态分布, } \mathbf{0} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} \text{ 是数学期望, } \sigma^2 I = \begin{bmatrix} \sigma^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma^2 \end{bmatrix} \text{ 是协方差矩阵}$$

问题： 已知数据矩阵 $X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1m} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{bmatrix}$ 和数据向量 $\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$,

求 β 的最小二乘估计 $\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_m \end{bmatrix}$, 使得下列平方和达到最小:

$$Q = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \cdots - \beta_m x_{im})^2$$

分析推导：

Q 是 $\beta_0, \beta_1, \dots, \beta_m$ 的函数, 所以这是一个多元函数求最小极值的问题

$$\left\{ \begin{array}{l} \frac{\partial Q}{\partial \beta_0} = 0 \\ \frac{\partial Q}{\partial \beta_1} = 0 \\ \dots\dots \\ \frac{\partial Q}{\partial \beta_m} = 0 \end{array} \right. \Rightarrow \hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_m \end{bmatrix} \Rightarrow \hat{\beta} = (X^T X)^{-1} X^T Y$$

$$Q = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_m x_{im})^2$$

$$= \begin{bmatrix} y_1 - \beta_0 - \beta_1 x_{11} - \dots - \beta_m x_{1m} \\ \vdots \\ y_n - \beta_0 - \beta_1 x_{n1} - \dots - \beta_m x_{nm} \end{bmatrix}^T \begin{bmatrix} y_1 - \beta_0 - \beta_1 x_{11} - \dots - \beta_m x_{1m} \\ \vdots \\ y_n - \beta_0 - \beta_1 x_{n1} - \dots - \beta_m x_{nm} \end{bmatrix}$$

$$= (Y - X \beta)^T (Y - X \beta) = Y^T Y - 2 \beta^T X^T Y + \beta^T X^T X \beta$$

$$\frac{\partial Q}{\partial \beta} = \frac{\partial}{\partial \beta} (Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta) = \mathbf{0} - 2X^T Y + 2X^T X \beta = \mathbf{0}$$

$$\text{用到: } \frac{\partial}{\partial x} A = \mathbf{0}, \quad \frac{\partial}{\partial x} (x^T A) = A, \quad \frac{\partial}{\partial x} (x^T A x) = (A + A^T)x$$

$$\frac{\partial Q}{\partial \beta} = \frac{\partial}{\partial \beta} (Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta) = \mathbf{0} - 2X^T Y + 2X^T X \beta = \mathbf{0}$$

$$X^T X \beta = X^T Y \quad \text{-----} \quad \text{正规方程}$$

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad \text{-----} \quad \hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_m \end{bmatrix} \text{的最小二乘估计}$$

$$\left. \begin{aligned} X^T X \beta &= X^T Y \\ \hat{Y} = \begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_n \end{bmatrix} &= X \hat{\beta} \end{aligned} \right\} \Rightarrow X^T \hat{Y} = X^T X \hat{\beta} = X^T Y$$

等式两边的第一个分量相等

$$\sum \hat{y}_i = \sum y_i$$

$$\hat{y}_i \text{ 的均值} = y_i \text{ 的均值 } \bar{y}$$

$$SS_e = Q_{\min} = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_m x_{im})^2$$

$$= Y^T Y - 2\hat{\beta}^T X^T Y + \hat{\beta}^T X^T X \hat{\beta}$$

由于 $\hat{\beta} = (X^T X)^{-1} X^T Y$, $\hat{\beta}^T X^T Y = \hat{\beta}^T X^T X \hat{\beta}$, 因此

$$SS_e = Y^T Y - \hat{\beta}^T X^T Y \quad \text{或} \quad SS_e = Y^T Y - \hat{\beta}^T X^T X \hat{\beta}$$

$$\hat{\sigma} = \sqrt{\frac{SS_e}{n-m-1}}$$

为估计标准差（或残差标准差）

$$r = \sqrt{1 - \frac{SS_e}{L_{yy}}} = ? = \sqrt{\frac{SS_R}{SS_T}}$$

为多重相关系数

$$L_{yy}$$

如果记: $S S_T = \sum_{i=1}^n (y_i - \bar{y})^2$ ——— 总离差平方和

$$S S_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$
 ——— 回归平方和

及前面讲到的:

$$S S_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$
 ——— 残差平方和

则可以证明:

$$S S_T = S S_R + S S_e$$
 ——— 离差分解公式

$$r = \sqrt{1 - \frac{SS_e}{L_{yy}}} = \sqrt{\frac{L_{yy} - SS_e}{L_{yy}}} = \sqrt{\frac{SS_T - SS_e}{SS_T}} = \sqrt{\frac{SS_R}{SS_T}}$$

$$r^2 = \frac{SS_R}{SS_T} \text{ ---判定系数, 反映回归方程对观测数据的拟和程度}$$

复相关系数 $r = \sqrt{\frac{SS_R}{SS_T}}$ 是因变元 y 与一组自变元 x_1, x_2, \dots, x_m 的相关系数,

这如何理解呢?

事实上, $r = \sqrt{\frac{SS_R}{SS_T}}$ 就是 $Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$ 与其回归估计值 $\hat{Y} = \begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_n \end{bmatrix}$ 的简单相关系数

证明: $Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$ 与 $\hat{Y} = \begin{bmatrix} \hat{y}_1 \\ \vdots \\ \hat{y}_n \end{bmatrix}$ 的简单相关系数为:

$$\frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum (y_i - \bar{y})^2 \sum (\hat{y}_i - \bar{y})^2}} = \frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{SS_T SS_R}}$$

要证: $\frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{SS_T SS_R}} = \sqrt{\frac{SS_R}{SS_T}}$

$$\Leftrightarrow \sum (y_i - \bar{y})(\hat{y}_i - \bar{y}) = SS_R$$

$$\Leftrightarrow \sum [(y_i - \bar{y}) - (\hat{y}_i - \bar{y})](\hat{y}_i - \bar{y}) = 0$$

$$\Leftrightarrow \sum y_i \hat{y}_i - \sum \hat{y}_i^2 = 0$$

$$\Leftrightarrow Y^T \hat{Y} = \hat{Y}^T \hat{Y} \Leftrightarrow Y^T (X \hat{\beta}) = (X \hat{\beta})^T (X \hat{\beta})$$

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

例1 设有多元线性回归模型

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i, \quad i = 1, 2, 3, 4,$$

其中, $\beta_0, \beta_1, \beta_2$ 是未知常数, $\varepsilon_i \sim N(0, \sigma^2)$, $i = 1, 2, 3, 4$, 相互独立。并且已知

$$x_{11} = 0, \quad x_{12} = 1, \quad y_1 = -2,$$

$$x_{21} = 1, \quad x_{22} = -1, \quad y_2 = 3,$$

$$x_{31} = 0, \quad x_{32} = -1, \quad y_3 = 2,$$

$$x_{41} = -1, \quad x_{42} = 1, \quad y_4 = 1.$$

求 $\beta_0, \beta_1, \beta_2$ 的最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ 。


解:
$$X = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ 1 & x_{41} & x_{42} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & -1 \\ 1 & 0 & -1 \\ 1 & -1 & 1 \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} -2 \\ 3 \\ 2 \\ 1 \end{bmatrix}$$

$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \hat{\beta} = (X^T X)^{-1} X^T Y = \begin{bmatrix} 1/4 & 0 & 0 \\ 0 & 1 & 1/2 \\ 0 & 1/2 & 1/2 \end{bmatrix} \begin{bmatrix} 4 \\ 2 \\ -6 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \\ -2 \end{bmatrix}$$

所以 $\beta_0, \beta_1, \beta_2$ 的最小二乘估计为 $\beta_0=1, \beta_1=-1, \beta_2=-2$

多元线性回归中统计量的分布

$$Y = X\beta + e, e \sim N_n(0, \sigma^2 I) \quad Y = X\beta + e, e \sim N_n(X\beta, \sigma^2 I)$$



$$\hat{\beta} \sim N_{m+1}(\beta, \sigma^2 (X^T X)^{-1})$$

$$\frac{S S e}{\sigma^2} \sim \chi^2(n - m - 1)$$

$$\hat{\beta}_j \sim N(\beta_j, c_{jj} \sigma^2), \quad (j=1, 2, \dots, m)$$

$$\text{其中 } (X^T X)^{-1} = (c_{ij})_{(m+1) \times (m+1)}$$

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{c_{jj}}} \sim t(n - m - 1)$$

定理8 $E(\hat{\beta}) = \beta, \quad D(\hat{\beta}) = \sigma^2(X^T X)^{-1}$

证： 由于 $Y \sim N_n(X\beta, \sigma^2 I)$, 所以 $E(Y) = X\beta, \quad D(Y) = \sigma^2 I$, 因此有

$$E(\hat{\beta}) = E[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T E(Y) = (X^T X)^{-1} X^T X\beta = \beta$$

$$D(\hat{\beta}) = D[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T D(Y) X (X^T X)^{-1}$$

$$= (X^T X)^{-1} X^T \sigma^2 I X (X^T X)^{-1}$$

$$= \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

定理9 $\hat{\beta} \sim N_m(\beta, \sigma^2(X^T X)^{-1})$

证： 因为 Y 服从正态分布，

而 $\hat{\beta} = (X^T X)^{-1} X^T Y$ 是 Y 的线性函数，

所以 $\hat{\beta}$ 也服从正态分布，

由定理8可知 $E(\hat{\beta}) = \beta$, $D(\hat{\beta}) = \sigma^2(X^T X)^{-1}$

因此, $\hat{\beta} \sim N_m(\beta, \sigma^2(X^T X)^{-1})$

定理10 $\frac{SS_e}{\sigma^2} \sim \chi^2(n-m-1)$, 而且 SS_e 与 $\hat{\beta}$ 相互独立

证: 因为 $Y = X\beta + e$, 所以 $e = Y - X\beta$

$$\begin{aligned} e^T e &= (Y - X\beta)^T (Y - X\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta \\ &= Y^T Y - \hat{\beta}^T X^T X \hat{\beta} + \hat{\beta}^T X^T X \hat{\beta} - 2\beta^T X^T X \hat{\beta} + \beta^T X^T X \beta \\ &= SS_e + (\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta) \end{aligned}$$

因为 $\varepsilon_i \sim N(0, \sigma^2)$, $i = 1, 2, \dots, n$ 相互独立,

所以 $\frac{\varepsilon_i}{\sigma} \sim N(0, 1)$, $i = 1, 2, \dots, n$ 相互独立

$$\sum_{i=1}^n \left(\frac{\varepsilon_i}{\sigma} \right)^2 = \frac{\sum_{i=1}^n \varepsilon_i^2}{\sigma^2} = \frac{e^T e}{\sigma^2} = \frac{SS_e + (\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)}{\sigma^2}$$

$$= \frac{SS_e}{\sigma^2} + \frac{(\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)}{\sigma^2} = Q_1 + Q_2$$

$$\text{其中 } Q_1 = \frac{SS_e}{\sigma^2} = \frac{\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_m x_{im})^2}{\sigma^2} = \frac{(Y - X \hat{\beta})^T (Y - X \hat{\beta})}{\sigma^2}$$

是 n 项的平方和，但这 n 项又满足 $m+1$ 个线性关系式

$$X^T (Y - X \hat{\beta}) = X^T Y - X^T X \hat{\beta} = X^T Y - X^T X (X^T X)^{-1} X^T Y = \mathbf{0}$$

所以 Q_1 的自由度 $f_1 = n - m - 1$

$$Q_2 = \frac{(\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)}{\sigma^2} \text{ 是 } m+1 \text{ 项平方和}$$

因为 $X^T X$ 的秩是 $m+1$ ，故存在 $m+1$ 阶方阵 P 使得：

$$(\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta) = (\hat{\beta} - \beta)^T P^T P (\hat{\beta} - \beta), \text{ 所以, } Q_2 \text{ 的自由度 } f_2 = m+1$$

因为 $f_1 + f_2 = (n - m - 1) + (m + 1) = n$,

所以由定理2.7（Cochran定理）可知：

$$Q_1 = \frac{SS_e}{\sigma^2} \sim \chi^2(n - m - 1),$$

$$Q_2 = \frac{(\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)}{\sigma^2} \sim \chi^2(m + 1)$$

而且 Q_1 , Q_2 相互独立, 所以 SS_e 与 $\hat{\beta}$ 相互独立

定理11 $E(SS_e) = (n - m - 1)\sigma^2$, $E(\hat{\sigma}^2) = \sigma^2$

证: 若 $\xi \sim \chi^2(n)$, 则 $E\xi = n$

由定理10可知, $\frac{SS_e}{\sigma^2} \sim \chi^2(n - m - 1)$, 所以 $E(\frac{SS_e}{\sigma^2}) = n - m - 1$, 因此

$$E(SS_e) = E(\frac{SS_e}{\sigma^2} \sigma^2) = E(\frac{SS_e}{\sigma^2}) \sigma^2 = (n - m - 1) \sigma^2$$

$$E(\hat{\sigma}^2) = E(\frac{SS_e}{n - m - 1}) = \frac{E(SS_e)}{n - m - 1} = \frac{(n - m - 1) \sigma^2}{n - m - 1} = \sigma^2$$

即 $\hat{\sigma}^2 = \frac{SS_e}{n - m - 1}$ 是 σ^2 的无偏估计

定理12 $\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}\sqrt{c_{jj}}} \sim t(n-m-1), j=1,2,\dots,m$

其中 C_{jj} 是矩阵 $(X^T X)^{-1} = \begin{bmatrix} c_{00} & \cdots & \cdots & c_{0m} \\ \vdots & c_{11} & & \vdots \\ \vdots & & \ddots & \vdots \\ c_{m0} & \cdots & \cdots & c_{mm} \end{bmatrix}$ 的第 $j+1$ 个对角元素

证： 由定理9可知 $\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_m \end{bmatrix} = \hat{\beta} \sim N_m(\beta, \sigma^2(X^T X)^{-1})$, 其中

数学期望 $\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}$, 协方差 $\sigma^2(X^T X)^{-1} = \sigma^2 \begin{bmatrix} c_{00} & \cdots & \cdots & c_{0m} \\ \vdots & c_{11} & & \vdots \\ \vdots & & \ddots & \vdots \\ c_{m0} & \cdots & \cdots & c_{mm} \end{bmatrix}$

所以 $\hat{\beta}_j \sim N(\beta_j, \sigma^2 c_{jj})$, 即 $\frac{\hat{\beta}_j - \beta_j}{\sigma\sqrt{c_{jj}}} \sim N(0, 1)$

$\frac{SS_e}{\sigma^2} \sim \chi^2(n-m-1)$, 而且 $\hat{\beta}$ 与 SS_e 相互独立,

$$\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{c_{jj}}} = \frac{\frac{\hat{\beta}_1 - \beta_1}{\sigma \sqrt{c_{jj}}}}{\sqrt{\frac{SS_e}{\sigma^2} / (n-m-1)}} \sim t(n-m-1)$$

多元线性回归中的假设检验

(1) 检验全部自变量 x_1, x_2, \dots, x_m 与因变量 y 之间是否有统计线性相关关系

相当于检验 回归模型 $y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$

中自变元的系数全部为零, 即 $H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$

因为 $y = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$

如果假设 H_0 为真, $\beta_1 = \beta_2 = \dots = \beta_m = 0$, 则有 $y = \beta_0 + \varepsilon$

说明 x_1, x_2, \dots, x_m 与 y 无关, 反之说明 x_1, x_2, \dots, x_m 与 y 有关

问题 已知有一组观测值 $(x_{i1}, x_{i2}, \dots, x_{im}, y_i)$, $i = 1, 2, \dots, n$, 设

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_m x_{im} + \varepsilon_i , \quad \varepsilon_i \sim N(0, \sigma^2) , \quad i = 1, 2, \dots, n$$

$\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 相互独立, 要检验 $H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$ 。

在 H_0 为真时, SS_R 与 SS_e 相互独立, $\frac{SS_R}{\sigma^2} \sim \chi^2(m)$,

$$F = \frac{SS_R / m}{SS_e / (n - m - 1)} \sim F(m, n - m - 1).$$

若 H_0 不真, 则 F 的值会偏大.

当 $F > F_{1-\alpha}(m, n - m - 1)$ 时拒绝 H_0 , 否则接受 H_0

(2) 检验某一个自变量 x_j 是否与因变量 y 统计线性相关

因为，在多元线性回归方程中，自变量不止一个，即使对全体自变量来说，已经可以肯定它们与因变量 y 有关，但是，对其中某一个自变量 x_j 来说，却不能保证它一定与 y 有关，所以，还需要作这方面的检验。

不难看出，检验 x_j 与 y 之间是否统计线性相关，相当于要检验这样一个假设 $H_{0j}: \beta_j = 0$ 。

$\beta_j = 0$ 时， $y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{j-1} x_{i,j-1} + 0 + \beta_{j+1} x_{i,j+1} + \cdots + \beta_m x_{im} + \varepsilon_i$ ， y 与 x_j 无关。

问题 已知有一组观测值 $(x_{i1}, x_{i2}, \cdots, x_{im}, y_i)$ ， $i = 1, 2, \cdots, n$ ，设

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_m x_{im} + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad i = 1, 2, \cdots, n$$

$\varepsilon_1, \varepsilon_2, \cdots, \varepsilon_n$ 相互独立，要检验 $H_{0j}: \beta_j = 0$ 。

检验方法一 (t 检验)

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{c_{jj}}} \sim t(n - m - 1)$$

若 H_{0j} 为真 $\beta_j = 0$, 有 $T_j = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{c_{jj}}} = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{c_{jj}}} \sim t(n - m - 1)$

当 $|T_j| > t_{1-\alpha/2}(n - m - 1)$ 时拒绝 H_{0j} , 否则接受 H_{0j}

检验方法二 (F 检验)

$$F_j = T_j^2 = \left(\frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{c_{jj}}} \right)^2 = \frac{\hat{\beta}_j^2 / c_{jj}}{SS_e / (n - m - 1)}$$

若 H_{0j} 为真 $\beta_j = 0$, 有 $F_j = T_j^2 \sim F(1, n - m - 1)$

若 $H_{0j}:\beta_j=0$ 不真, 则 T_j 的绝对值会偏大, 则 $F_j = T_j^2$ 的值也会偏大

当 $F > F_{1-\alpha}(m, n - m - 1)$ 时拒绝 H_{0j}

例2 对某种化工产品的产量 y （单位：kg），生产时的处理压力 x_1 （单位：大气压）和温度 x_2 作测量，得数据如下：

压力	温度	产量
x_{i1}	x_{i2}	y_i
6.8	665	40
7.2	685	49
7.6	690	55
8.0	700	63
8.2	695	65

压力	温度	产量
x_{i1}	x_{i2}	y_i
8.4	670	57
8.6	675	58
8.8	690	62
9.1	700	65
9.3	680	58

压力	温度	产量
x_{i1}	x_{i2}	y_i
9.5	685	59
9.7	700	67
10.0	650	56
10.3	690	72
10.5	670	68

设有 $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$ ， $\varepsilon_i \sim N(0, \sigma^2)$ ， $i = 1, 2, \dots, 15$ ， $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_{15}$ 相互独立。

求：（1） $\beta_0, \beta_1, \beta_2$ 的最小二乘估计 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ ；

（2）残差平方和 SS_e ，估计的标准差 $\hat{\sigma}$ ，多重相关系数 r ；

（3）检验 $H_0: \beta_1 = \beta_2 = 0$ （显著水平 $\alpha = 0.05$ ）；

（4）分别检验 $H_{01}: \beta_1 = 0$ 和 $H_{02}: \beta_2 = 0$ （显著水平 $\alpha = 0.05$ ）

解： 利用可作多元线性回归的计算机软件，求得：

(1) $\hat{\beta}_0 = -200.455$, $\hat{\beta}_1 = 5.68337$, $\hat{\beta}_2 = 0.307528$, 所以，回归方程为

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = -200.455 + 5.68337x_1 + 0.307528x_2$$

(2) 残差平方和 $SS_e = 123.806$, 估计的标准差 $\hat{\sigma} = 3.212$,
多重相关系数 $r = 0.9285$

(3) 检验 $H_0: \beta_1 = \beta_2 = 0$ 的统计量 $F = 37.50$,

对 $\alpha = 0.05$, 查F分布表, 可得分为数:

$$F_{1-\alpha}(m, n-m-1) = F_{0.95}(2, 12) = 3.89 ,$$

因为 $F = 37.50 > 3.89$, 所以拒绝 $H_0: \beta_1 = \beta_2 = 0$,

说明自变量 x_1, x_2 与因变量 y 之间有显著的统计线性相关关系

(4) 检验 $H_{01}: \beta_1 = 0$ 的统计量 $F_1 = 54.10$

$$F_{1-\alpha}(1, n-m-1) = F_{0.95}(1, 12) = 4.75,$$

因为 $F_1 = 54.10 > 4.75$, 所以拒绝 $H_{01}: \beta_1 = 0$

检验 $H_{02}: \beta_2 = 0$ 的统计量 $F_2 = 27.19$

$$F_{1-\alpha}(1, n-m-1) = F_{0.95}(1, 12) = 4.75$$

因为 $F_2 = 27.19 > 4.75$, 所以拒绝 $H_{02}: \beta_2 = 0$

线性回归的方差分析表

方差源	离差平方和	自由度	F 值	p 值
回归	SS_R	$f_R = m$	$F = \frac{SS_R / f_R}{SS_e / f_E}$	$p = P\{F(m, n - m - 1) > F\}$
残差	SS_e	$f_E = n - m - 1$		
总计	SS_T	$f_T = n - 1$		

统计量观测值 $F >$ 分位数 \longleftrightarrow p 值小于给定显著性水平

例 3 设 $\theta_i, i=1,2,3$ 是一个三角形的三个角, 它们的观测值分别为 $y_i, i=1,2,3$, 每次观测的误差

$\varepsilon_i \sim N(0, \sigma^2), i=1,2,3, \varepsilon_1, \varepsilon_2, \varepsilon_3$ 相互独立。求:

(1) $\theta_i, i=1,2,3$ 的估计值; (2) σ^2 的估计值; (3) 检验 $H_{0i}: \theta_i = \theta_{i0}$ 的检验方法。

解 因为 $\theta_1 + \theta_2 + \theta_3 = \pi$, 只有 $m=2$ 个独立的未知参数, 所以, 只要考虑 θ_1, θ_2 的回归就可以了

回归方程为 $y = \theta_1 x_1 + \theta_2 x_2 + \varepsilon$, $n=3$ 次观测对应于
$$\begin{cases} y_1 = \theta_1 + \varepsilon_1 \\ y_2 = \theta_2 + \varepsilon_2 \\ \pi - y_3 = \theta_1 + \theta_2 + \varepsilon_3 \end{cases}$$

即有 $Y = X\theta + e$, 其中 $Y = \begin{bmatrix} y_1 \\ y_2 \\ \pi - y_3 \end{bmatrix}, X = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, e = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \end{bmatrix}。$

这是一个不含常数项的多元线性回归模型, 可以像含有常数项的多元线性回归模型一样

唯一不同是:含有常数项的多元线性回归模型中**m+1**,在不含常数的多元线性回归

(m+1)  m

$$\begin{aligned} (1) \quad \begin{bmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \end{bmatrix} &= \hat{\theta} = (X^T X)^{-1} X^T Y = \left(\begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \pi - y_3 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}^{-1} \begin{bmatrix} y_1 + \pi - y_3 \\ y_2 + \pi - y_3 \end{bmatrix} = \begin{bmatrix} 2/3 & -1/3 \\ -1/3 & 2/3 \end{bmatrix} \begin{bmatrix} y_1 + \pi - y_3 \\ y_2 + \pi - y_3 \end{bmatrix} = \begin{bmatrix} \frac{\pi + 2y_1 - y_2 - y_3}{3} \\ \frac{\pi - y_1 + 2y_2 - y_3}{3} \end{bmatrix} \end{aligned}$$

(2) 残差平方和

$$\begin{aligned}SS_e &= (y_1 - \hat{\theta}_1)^2 + (y_2 - \hat{\theta}_2)^2 + (y_3 - \hat{\theta}_3)^2 \\&= (y_1 - y_1 - \frac{\pi - y_1 - y_2 - y_3}{3})^2 + (y_2 - y_2 - \frac{\pi - y_1 - y_2 - y_3}{3})^2 + (y_3 - y_3 - \frac{\pi - y_1 - y_2 - 2y_3}{3})^2 \\&= 3(-\frac{\pi - y_1 - y_2 - y_3}{3})^2 = \frac{(\pi - y_1 - y_2 - y_3)^2}{3}.\end{aligned}$$

可以证明 $\frac{SS_e}{\sigma^2} \sim \chi^2(n-m)$, 所以 $E(\frac{SS_e}{\sigma^2}) = n-m$, 即有 $E(\frac{SS_e}{n-m}) = \sigma^2$

$$\hat{\sigma}^2 = \frac{SS_e}{n-m} = \frac{1}{3-2} \cdot \frac{(\pi - y_1 - y_2 - y_3)^2}{3} = \frac{(\pi - y_1 - y_2 - y_3)^2}{3}$$

(3) 因为 $\begin{bmatrix} \hat{\theta}_1 \\ \hat{\theta}_1 \end{bmatrix} \sim N\left(\begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \sigma^2(X^T X)^{-1}\right) = N\left(\begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}, \sigma^2 \begin{bmatrix} 2/3 & -1/3 \\ -1/3 & 2/3 \end{bmatrix}\right)$, 所以

$$\hat{\theta}_i \sim N(\theta_i, \frac{2}{3}\sigma^2) , \quad \frac{\hat{\theta}_i - \theta_i}{\sigma} \sqrt{\frac{3}{2}} \sim N(0,1) , \quad i=1,2 \quad .$$

再加上有 $\frac{(n-m)\hat{\sigma}^2}{\sigma^2} = \frac{SS_e}{\sigma^2} \sim \chi^2(n-m)$, 且与上式独立, 所以当 $H_0: \theta_i = \theta_{i0}$ 为真时, 有

$$T_i = \frac{\hat{\theta}_i - \theta_{i0}}{\hat{\sigma}} \sqrt{\frac{3}{2}} = \frac{\hat{\theta}_i - \theta_i}{\hat{\sigma}} \sqrt{\frac{3}{2}} = \frac{\frac{\hat{\theta}_i - \theta_i}{\sigma} \sqrt{\frac{3}{2}}}{\sqrt{\frac{(n-m)\hat{\sigma}^2}{\sigma^2} / (n-m)}} \sim t(n-m) = t(1) , \quad i=1,2 \quad .$$

因此, 检验假设 $H_0: \theta_i = \theta_{i0}$ 的 t 分布检验方法为:

$$\text{求出统计量 } T_i = \frac{\hat{\theta}_i - \theta_{i0}}{\hat{\sigma}} \sqrt{\frac{3}{2}} = \frac{y_i + \frac{\pi - y_1 - y_2 - y_3}{3} - \theta_{i0}}{\sqrt{\frac{(\pi - y_1 - y_2 - y_3)^2}{3}}} \sqrt{\frac{3}{2}} = \frac{3y_i - 3\theta_{i0} + \pi - y_1 - y_2 - y_3}{\sqrt{2} |\pi - y_1 - y_2 - y_3|} \quad \text{的值, 对给}$$

定的显著水平 α , 查 t 分布表, 可得 $t_{1-\alpha/2}(n-m) = t_{1-\alpha/2}(1)$, 当 $|T_i| > t_{1-\alpha/2}(1)$ 时拒绝 $H_0: \theta_i = \theta_{i0}$, 否则接受 H_0 .

思考题

- 1) 以上多元回归的方法和结论有个假设, 即 $X'X$ 可逆, 这等价于 X 满秩。如果这个条件不满足怎么办?

-----参见5.5节 逐步回归方法

- 2) 多元线性回归的第二个前提是误差服从正态分布, 如果不是正态分布怎么办?

-----参阅基于指数分布族的广义回归

- 3) 变元间是非线性关系, 如何求回归方程?

5.4 非线性回归

可以化为线性的非线性回归——广义线性回归

例1 某零件上有一条曲线，可以近似看作是一条抛物线，为了在数控机床上加工这一零件，在曲线上测得 n 个点的坐标 (x_i, y_i) ， $i = 1, 2, \dots, n$ ，要求从这 n 个点的坐标出发，求出曲线的函数表达式。

显然，这是一个回归分析问题，由于曲线可以近似看作是一条抛物线，因此， $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$ 回归方程（即曲线的函数表达式）是一个二次多项式，它不是线性的，但可以通过变量代换，化成线性形式。

令 $x_1 = x$ ， $x_2 = x^2$ ，原来的回归方程化成了下列形式：

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

例2:

在经济学中，有一个著名的科布－道格拉斯(Cobb－Douglas) 生产函数，这个函数指出，生产产出与劳动投入、资本投入之间，近似有下列关系：

$$Y = \alpha L^{\beta_1} K^{\beta_2}$$

其中， α, β_1, β_2 都是常系数。现测得一组劳动投入、资本投入和生产产出的数据 $(L_i, K_i, Y_i), i = 1, 2, \dots, n$ ，要求从这批数据出发，估计常系数 α, β_1, β_2 的值。

这是一个回归分析问题，回归方程为 $\hat{Y} = \hat{\alpha} L^{\hat{\beta}_1} K^{\hat{\beta}_2}$ ，它不是线性回归方程，但是，如果我们对方程两边同时取对数，得到

$$\ln \hat{Y} = \ln \hat{\alpha} + \hat{\beta}_1 \ln L + \hat{\beta}_2 \ln K$$

再令 $y^* = \ln Y, \beta_0 = \ln \alpha, x_1 = \ln L, x_2 = \ln K$ ，它就化成了一个多元线性回归方程

$$\hat{y}^* = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$


例3 在混合异辛烯催化反应中，反应速度 y 与氢的分压 x_1 ，异辛烯的分压 x_2 ，异辛烷的分压 x_3 之间，近似有下列关系：

$$y = \frac{kx_1x_2}{(1 + a\sqrt{x_1} + bx_2 + cx_3)^3}$$

其中， k, a, b, c 是常系数，现对 x_1, x_2, x_3, y ，得到观测值 $(x_{i1}, x_{i2}, x_{i3}, y_i)$ ， $i = 1, 2, \dots, n$ ，要求常系数 k, a, b, c 的估计值

对非线性回归方程 $\hat{y} = \frac{\hat{k}x_1x_2}{(1 + \hat{a}\sqrt{x_1} + \hat{b}x_2 + \hat{c}x_3)^3}$ 两边开3次方，再取倒数，得到

$$\frac{1}{\sqrt[3]{\hat{y}}} = \frac{1}{\sqrt[3]{\hat{k}x_1x_2}} + \frac{\hat{a}\sqrt{x_1}}{\sqrt[3]{\hat{k}x_1x_2}} + \frac{\hat{b}x_2}{\sqrt[3]{\hat{k}x_1x_2}} + \frac{\hat{c}x_3}{\sqrt[3]{\hat{k}x_1x_2}}$$



$$\hat{y}^* = \hat{\beta}_1 z_1 + \hat{\beta}_2 z_2 + \hat{\beta}_3 z_3 + \hat{\beta}_4 z_4$$

广义线性回归一般形式和解法

问题 设自变量 x_1, x_2, \dots, x_m 与因变量 y 之间, 有下列关系:

$y = f(\beta_0 + \beta_1\phi_1(x_1, \dots, x_m) + \dots + \beta_p\phi_p(x_1, \dots, x_m)) + \varepsilon$ 其中,
 $y = f(y^*)$ 是已知的一元函数, 有唯一的反函数 $y^* = f^{-1}(y)$,
 $\phi_1(x_1, \dots, x_m)$, 是自变量 x_1, x_2, \dots, x_m 的不含未知参数的函数,
 $\beta_0, \beta_1, \dots, \beta_m$ 是常系数, $\varepsilon \sim N(0, \sigma^2)$ 是表示误差的随机变量,
 $\sigma > 0$, 对 x_1, x_2, \dots, x_m , y 进行 n 次观测, 得到观测值:

$$(x_{i1}, x_{i2}, \dots, x_{im}, y_i), \quad i = 1, 2, \dots, n$$

求 $\beta_0, \beta_1, \dots, \beta_m$ 的估计 $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_m$, 使得下式达到最小值:

$$Q = \sum_{i=1}^n [y_i - f(\beta_0 + \beta_1\phi_1(x_{i1}, \dots, x_{im}) + \dots + \beta_p\phi_p(x_{i1}, \dots, x_{im}))]^2$$

分析推导:

对回归方程 $\hat{y} = f(\hat{\beta}_0 + \hat{\beta}_1\phi_1(x_1, \dots, x_m) + \dots + \hat{\beta}_p\phi_p(x_1, \dots, x_m))$ 的
两边同时取反函数 f^{-1} ,得到

$$f^{-1}(\hat{y}) = \hat{\beta}_0 + \hat{\beta}_1\phi_1(x_1, \dots, x_m) + \dots + \hat{\beta}_p\phi_p(x_1, \dots, x_m)$$

令 $y^* = f^{-1}(y)$, $z_1 = \phi_1(x_1, \dots, x_m)$, \dots , $z_p = \phi_p(x_1, \dots, x_m)$ 上述
方程就化成了线性回归方程 $\hat{y}^* = \hat{\beta}_0 + \hat{\beta}_1z_1 + \hat{\beta}_2z_2 + \dots + \hat{\beta}_pz_p$

用线性回归的方法可以求出它的解, 得到常系数 $\beta_0, \beta_1, \dots, \beta_m$ 的估计
 $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_m$

广义线性回归中的加权处理

有些广义线性回归问题，化为线性时不需要取反函数 $y^* = f^{-1}(y)$ ，有些则要取反函数 $y^* = f^{-1}(y)$ 。对于要取反函数的广义线性回归问题取了反函数后，得到的新问题并不完全等价于原问题。

原问题 设自变量 x 与因变量 y 之间，有下列关系：

$$y = f(\beta_0 + \beta_1 x) + \varepsilon$$

求 β_0, β_1 的估计 $\hat{\beta}_0, \hat{\beta}_1$ ，使得下式达到最小：

$$Q = \sum_{i=1}^n [y_i - f(\beta_0 + \beta_1 x_i)]^2$$

化为线性后的新问题

在自变量 x 与因变量 y 之间的关系式两边取反函数 $f^{-1}(y)$ ，得到

$$Q^* = \sum_{i=1}^n [f^{-1}(y_i) - (\beta_0 + \beta_1 x_i)]^2$$

原来各点到曲线的距离并不等于变换后各点到直线的距离，

所以 $\hat{\beta}_0^* \neq \hat{\beta}_0$, $\hat{\beta}_1^* \neq \hat{\beta}_1$

为了解决这一问题，有人提出一种“加权处理”方法

我们知道，当 $a \approx b$ 时，有 $f'(a) \approx \frac{f(a) - f(b)}{a - b}$

即有 $f(a) - f(b) \approx f'(a)(a - b)$

现在因为 $f^{-1}(y_i) \approx \beta_0 + \beta_1 x_i$ ，所以

$$\begin{aligned} y_i - f(\beta_0 + \beta_1 x_i) &= f(f^{-1}(y_i)) - f(\beta_0 + \beta_1 x_i) \\ &\approx f'(f^{-1}(y_i))[f^{-1}(y_i) - (\beta_0 + \beta_1 x_i)] \end{aligned}$$

所以

$$\begin{aligned} Q &= \sum_{i=1}^n [y_i - f(\beta_0 + \beta_1 x_i)]^2 \approx \sum_{i=1}^n \{f'(f^{-1}(y_i))[f^{-1}(y_i) - (\beta_0 + \beta_1 x_i)]\}^2 \\ &= \sum_{i=1}^n W_i [f^{-1}(y_i) - (\beta_0 + \beta_1 x_i)]^2 \end{aligned}$$

其中 $W_i = [f'(f^{-1}(y_i))]^2$ 称为权 (**Weight**)。

因此，原问题可以近似等价于下列加权回归问题：

求 β_0, β_1 的估计 $\hat{\beta}_0^w, \hat{\beta}_1^w$ ，使得下式达到最小：

$$Q^w = \sum_{i=1}^n W_i [f^{-1}(y_i) - (\beta_0 + \beta_1 x_i)]^2$$

由于 $Q^w \approx Q$ ，所以求得的加权最小二乘估计 $\hat{\beta}_0^w \approx \hat{\beta}_0, \hat{\beta}_1^w \approx \hat{\beta}_1$

例4 在彩色显影中，形成染料的光学密度 y 与析出银的光学密度 x 之间，近似有下列关系：

$$y = \alpha e^{\beta/x},$$

其中， α, β 是常系数。现测得数据如下：

x_i	0.05	0.06	0.07	0.10	0.14	0.20	0.25	0.31	0.38	0.43	0.47
y_i	0.10	0.14	0.23	0.37	0.59	0.79	1.00	1.12	1.19	1.25	1.29

求 y 关于 x 的回归方程。

解 对回归方程 $\hat{y} = \hat{\alpha} e^{\hat{\beta}/x}$ 两边同时取对数，得到

$$\ln \hat{y} = \ln \hat{\alpha} + \hat{\beta}/x。$$

令 $y^* = \ln y$ ， $\beta_0 = \ln \alpha$ ， $\beta_1 = \beta$ ， $z = 1/x$ ，就把它化成了一个一元线性回归方程

$$\hat{y}^* = \hat{\beta}_0 + \hat{\beta}_1 z。$$

用 $\ln y_i$ 的值, 作为因变量 y^* 观测值 y_i^* , 用 $1/x_i$ 的值, 作为自变量 z 的观测值 z_i , 代入一元线性回归的计算公式, 可以求得 $\hat{\beta}_0 = 0.54765$, $\hat{\beta}_1 = -0.14593$, 再从下式可以得到原方程中常系数的估计 $\hat{\alpha} = \exp(\hat{\beta}_0) = 1.7292$, $\hat{\beta} = \hat{\beta}_1 = -0.14593$, 所以, 要求的回归方程为

$$\hat{y} = \hat{\alpha} e^{\hat{\beta}/x} = 1.7292 e^{-0.14593/x}。$$

它的残差平方和为 $SS_e = 0.0075653$ 。

以上是在未加权的情况下得到的结果。

在加权的情况下可以求得 $\hat{\beta}_0 = 0.58117$, $\hat{\beta}_1 = -0.15240$, 再从下式可以得到原方程中常系数的估计 $\hat{\alpha} = \exp(\hat{\beta}_0) = 1.7881$, $\hat{\beta} = \hat{\beta}_1 = -0.15240$, 所以, 要求的回归方程为

$$\hat{y} = \hat{\alpha} e^{\hat{\beta}/x} = 1.7881 e^{-0.15240/x}。$$

它的残差平方和为 $SS_e = 0.0050496$ 。

与不加权时的情况相比, 加权时的残差平方和要小很多, 说明加权后得到的回归方程, 比起不加权得到的回归方程来, 对原始数据拟合得更好, 能够更精确地反映自变量与因变量之间的关系。

不能化为线性的非线性回归

问题 设自变量 x_1, x_2, \dots, x_m 与因变量 y 之间, 有下列关系

$$y = F(x_1, x_2, \dots, x_m; a_1, a_2, \dots, a_p) + \varepsilon$$

其中, F 是函数形式已知的 m 元函数, a_1, a_2, \dots, a_p 是常数, $\varepsilon \sim N(0, \sigma^2)$

对 x_1, x_2, \dots, x_m, y 进行 n 次观测, 得到一组观测值:

$$(x_{i1}, x_{i2}, \dots, x_{im}, y_i), i = 1, 2, \dots, n$$

求 a_1, a_2, \dots, a_p 的估计 $\hat{a}_1, \hat{a}_2, \dots, \hat{a}_p$, 使得下式达到最小:

$$Q = \sum_{i=1}^n [y_i - F(x_{i1}, x_{i2}, \dots, x_{im}; a_1, a_2, \dots, a_p)]^2$$

分析推导:

$$Q = \sum_{i=1}^n [y_i - F(x_{i1}, x_{i2}, \dots, x_{im}; a_1, a_2, \dots, a_p)]^2$$
是 a_1, a_2, \dots, a_p 的函数, 所以, 这是一个

多元函数求最小值的问题。

$$Q = \sum_{i=1}^n [y_i - F(x_{i1}, x_{i2}, \dots, x_{im}; a_1, a_2, \dots, a_p)]^2 \text{ 是 } a_1, a_2, \dots, a_p \text{ 的函数,}$$


所以，这是一个多元函数求最小值的问题

我们能不能象在线性回归中那样，求的偏导数，令偏导数为 0，得到一组方程，然后通过解方程组的方法，来确定的最小值点呢？

$$\begin{cases} \frac{\partial Q}{\partial a_1} = 0 \\ \frac{\partial Q}{\partial a_2} = 0 \\ \dots \\ \frac{\partial Q}{\partial a_p} = 0 \end{cases}$$

从理论上说来，这样做是没有问题的


但是，在许多实际情况下，这样做却是行不通的



其实，对于这样一个多元函数求最小值的问题，人们已经提出了许多求近似解的数值方法。这些方法的基本思想是：从一个初始值出发，逐步搜索最优解，搜索的步长逐渐缩小，当搜索的步长或最优解的变化小于事先给定的一个误差水平界限时，搜索结束，给出问题的近似解。

在借助计算机软件进行求解的过程中，可能会出现许多问题，例如：

- (1) 逐步搜索超出函数的定义域，发生计算溢出；
- (2) 发生“死循环”，长期得不到解；
- (3) 得到的解不是真正的最优解，等等。



要避免发生这样的问题，选择适当的初始值非常重要。最好能够根据问题的实际意义，参考文献资料和类似的先例，确定比较合理的初始值。还有一种方法，是将问题先作一些简化或转换，变成能用其他回归方法求解的问题，用其他方法求出初步的近似解，再用这个解作为非线性回归的初始值。

例5 对肉鸡的饲养天数 x （单位：日）和肉鸡的重量 y （单位：kg）进行观测，得到一组数据如下：

饲养天数 x_i	4	8	12	16	20	24	28	32	36
重量 y_i	0.070	0.119	0.198	0.297	0.434	0.606	0.803	1.027	1.245

饲养天数 x_i	40	44	48	52	56	60	64	68
重量 y_i	1.488	1.736	1.980	2.170	2.450	2.687	2.915	3.095

肉鸡重量 y 与饲养天数 x 之间的关系，满足下列微分方程及初始条件：

$$\begin{cases} \frac{dy}{dx} = k y \left(1 - \frac{y}{w}\right) \\ y|_{x=0} = y_0 \end{cases}$$

其中， k, w, y_0 是未知常数。求肉鸡重量 y 与饲养天数 x 之间的函数关系。

解 在初始条件下解微分方程，可求得

$$y = \frac{w}{1 + \left(\frac{w}{y_0} - 1\right)e^{-kx}} \quad .$$

在上式中，常数 w, y_0, k 未知，所以，要得到肉鸡重量 y 与饲养天数 x 之间的关系式，必须从 x 与 y 的观测数据出发，求出 w, y_0, k 的估计值。

这是一个非线性回归问题，回归方程为

$$\hat{y} = \frac{\hat{w}}{1 + (\frac{\hat{w}}{\hat{y}_0} - 1)e^{-\hat{k}x}} \quad .$$

利用可以作非线性回归的计算机软件，将数据代入，计算求得 w, y_0, k 的估计值

$$\hat{w} = 3.53348 \quad , \quad \hat{y}_0 = 0.106883 \quad , \quad \hat{k} = 0.0776665 \quad .$$

所以，我们得到肉鸡重量 y 与饲养天数 x 之间的函数关系为

$$\hat{y} = \frac{3.53348}{1 + (\frac{3.53348}{0.106883} - 1)e^{-0.0776665x}} = \frac{3.53348}{1 + 32.0593 e^{-0.0776665x}} \quad .$$

它的残差平方和为 $SS_e = 0.0424689$ 。这个值相当小，说明回归效果还是很好的。