

第六章 非线性规划



Non-linear Programming

非线性规划

- ❖ 基本概念
- ❖ 凸函数和凸规划
- ❖ 一维搜索方法
- ❖ 无约束最优化方法
- ❖ 约束最优化方法

第一节 基本概念

1、非线性规划模型：

➤数学规划模型的一般形式：

$$\begin{cases} \min & f(x) \\ s.t. & g_i(x) \leq 0, \quad i=1, \dots, p \\ & h_j(x) = 0, \quad j=1, \dots, q \end{cases}$$

其中, $x=(x_1, x_2, \dots, x_n)^T$, $f(x), g_i(x), h_j(x)$ 为 x 的实值函数

简记为MP(Mathematical Programming)

无约束问题:

$$\min f(x), \quad x \in R^n$$

约束问题:

$$\begin{aligned} \min f(x) \quad s.t. \quad & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \geq 0, \quad j = 1, \dots, l \end{aligned}$$

$$\Leftrightarrow \min f(x) \quad s.t. \quad h(x) = 0, \quad g(x) \geq 0$$

$$\Leftrightarrow \min f(x) \quad s.t. \quad x \in D = \{x \mid h(x) = 0, g(x) \geq 0\}$$

D 称为可行域。


非线性规划问题举例

例1 曲线的最优拟合问题

已知某物体的温度 φ 与时间 t 之间有如下形式的经验函数关系：

$$\varphi = c_1 + c_2 t + e^{c_3 t} \quad (*)$$

其中 c_1, c_2, c_3 是待定参数。现通过测试获得 n 组 φ 与 t 之间的实验数据 (t_i, φ_i) , $i=1, 2, \dots, n$ 。试确定参数 c_1, c_2, c_3 , 使理论曲线(*)尽可能地与 n 个测试点 (t_i, φ_i) 拟合。




$$\min \sum_{i=1}^n [\varphi_i - (c_1 + c_2 t_i + e^{c_3 t_i})]^2$$

例2 构件容积问题

设计一个右图所示的由圆锥和圆柱面围成的构件，要求构件的表面积为 S ，圆锥部分的高 h 和圆柱部分的高 x_2 之比为 a 。确定构件尺寸，使其容积最大。

$$\begin{cases} \max V = (1 + a/3)\pi x_1^2 x_2 \\ s.t. \pi x_1 \sqrt{x_1^2 + a^2 x_2^2} + 2\pi x_1 x_2 + \pi x_1^2 = S \\ x_1 \geq 0, x_2 \geq 0 \end{cases}$$



2、非线性规划方法概述

➤微分学方法的局限性:

实际的问题中，函数可能是不连续或者不可微的。

需要解复杂的方程组，而方程组到目前仍没有有效的算法。

实际的问题可能含有不等式约束，微分学方法不易处理。

基本概念

整体最优解 $x^* : f(x^*) \leq f(x), \forall x \in D$

邻域 $N(\hat{x}, \delta) = \{ x \mid \|x - \hat{x}\| < \delta \}$

局部最优解 $x^* : f(x^*) \leq f(x), \forall x \in N(x^*, \delta) \cap D$


定义：下降方向

设 $f: R^n \rightarrow R^1, \bar{x} \in R^n, p \in R^n, p \neq 0$, 若存在 $\delta > 0$, 使

$$f(\bar{x} + tp) < f(\bar{x}), \quad \forall t \in (0, \delta)$$

则称向量 p 是函数 $f(x)$
在点 \bar{x} 处的下降方向。

若 $f(x)$ 在 \bar{x} 可导, 则 $-\nabla f(\bar{x})$ 就是
 $f(x)$ 在 \bar{x} 处下降最快的方向。




定义 设 $X \subset R^n, \bar{x} \in X, p \in R^n, p \neq 0$, 若存在 $t > 0$, 使得

$$\bar{x} + tp \in X$$

则称向量 p 是点 \bar{x} 处
关于 X 的可行方向。

解非线性规划问题，关键在于找到某个方向，使得在此方向上，目标函数得到下降，同时还是可行方向。

这样的方向称为可行下降方向。



非线性规划基本下降迭代格式


第一步: 给定初始点 x^0 , 设 $k=0$;

第二步: 按照某种规则确定搜索方向 p^k ;

第三步: 按照某种规则确定搜索步长 t_k ;

第四步: 计算 $x^{k+1} = x^k + t_k p^k$;

检查得到的 x^{k+1} 是否满足终止准则: 是, $x^* = x^{k+1}$, 终止; 否, $k = k+1$, 转步骤第二步。



迭代算法中如何确定搜索步长 t_k ?

- (1) 定步长, 即取 t_k 等于某一常数。
- (2) 可接受点法, 即任意选取能使目标函数值下降的 t_k 。
- (3) (精确) 一维搜索, 即求解一元函数极小化问题:

$$f(x^k + t_k p^k) = \min_{t \geq 0} f(x^k + t p^k)$$

性质: 若 $f(x)$ 连续可微, t_k 由精确一维搜索确定, 则

$$\nabla f(x^{k+1})^T p^k = 0$$

证明: 考虑函数 $\phi(t) = f(x^k + t p^k)$, 则 t_k 是 $\phi(t)$ 的

极小点, 所以 $\phi'(t_k) = \nabla f(x^k + t_k p^k)^T p^k = 0$,

即 $\nabla f(x^{k+1})^T p^k = 0$ 。

若迭代算法产生的点列 $\{x^k\}$ 满足

$$f(x^0) > f(x^1) > \cdots > f(x^k) > f(x^{k+1}) > \cdots$$

称为下降算法。

若迭代点列 $\{x^k\}$ 有子序列收敛于问题的解 x^* ，
则称该迭代算法收敛。

若对于任意初始点 x^0 ，迭代算法收敛，则称为全局收敛；

若仅当 x^0 属于 x^* 的某个邻域时，迭代算法收敛，
则称为局部收敛。

终止准则:

$$(1) \quad \|x^{k+1} - x^k\| < \varepsilon$$


$$(2) \quad |f(x^{k+1}) - f(x^k)| < \varepsilon$$

$$(3) \quad \frac{\|x^{k+1} - x^k\|}{\|x^k\|} < \varepsilon \quad (\|x^k\| > \varepsilon_0)$$

$$(4) \quad \frac{|f(x^{k+1}) - f(x^k)|}{|f(x^k)|} < \varepsilon \quad (|f(x^k)| > \varepsilon_0)$$

$$(5) \quad \|\nabla f(x^k)\| < \varepsilon$$

注: $(3) \Rightarrow (1) \quad \|x^{k+1} - x^k\| < \varepsilon \not\Rightarrow \|x^{k+1} - x^*\| < \varepsilon$
 $(4) \Rightarrow (2)$



第二节 凸函数和凸规划

1、凸函数及其性质：

定义 凸集：设 $S \subseteq R^n$ ，若任给 $x^1, x^2 \in S$ 和 $0 \leq \lambda \leq 1$ ，
 $\lambda x^1 + (1 - \lambda)x^2 \in S$ ，则称 S 是凸集。

定义： 凸函数

设 $S \subset R^n$ 是非空凸集， $f: S \rightarrow R^1$ ，若对 $\forall \alpha \in (0, 1)$ 有

$$f(\alpha x^1 + (1 - \alpha)x^2) \leq \alpha f(x^1) + (1 - \alpha)f(x^2), \forall x^1, x^2 \in S$$

则称 f 是 S 上的凸函数，或 f 在 S 上是凸的。

例 $f(x) = \alpha^T x + \beta$ ，其中 $\alpha, x \in R^n, \beta \in R^1$ 即是凸的也是凹的。

例 $f(x) = \|x\|$ 其中 $x \in R^n$ 是凸函数

严格凸函数

若 $f(\alpha x^1 + (1-\alpha)x^2) < \alpha f(x^1) + (1-\alpha)f(x^2), \forall x^1, x^2 \in S$

则称 f 是 S 上的严格凸函数，或 f 在 S 上是严格凸的。

若 $-f$ 是 S 上的(严格)凸函数，称 f 是 S 上的(严格)凹函数,或 f 在 S 上是(严格)凹的。

性质 $f(x)$ 为凸函数

$$\Leftrightarrow f(x^2) \geq f(x^1) + \nabla f(x^1)^T (x^2 - x^1) \quad \forall x^1, x^2$$

$$\Leftrightarrow \forall x, \text{ Hesse 阵 } \nabla^2 f(x) \text{ 半正定。}$$

定理 设 $S \subset R^n$ 是非空开凸集, $f:S \rightarrow R^1$ 二阶连续可导,
则 f 是 S 上的凸函数的充要条件是

$\nabla^2 f(x)$ 在 S 上是半正定的。

当 $\nabla^2 f(x)$ 在 S 上是正定矩阵时, f 是 S 上的严格
凸函数 (此时,逆命题不成立)

$\nabla^2 f(x)$ 称为*Hesse*矩阵,

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \cdots & \cdots & \cdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n \partial x_n} \end{bmatrix}$$

例 验证下列 MP 是凸规划

$$\left\{ \begin{array}{l} \min f(x_1, x_2, x_3) = 2x_1^2 + x_2^2 + 2x_3^2 + x_1x_3 - x_1x_2 + x_1 + 2x_2 \\ s.t. \quad g_1(x) = x_1^2 + x_2^2 - x_3 \leq 0 \\ \quad \quad g_2(x) = x_1 + x_2 + 2x_3 \leq 16 \\ \quad \quad g_3(x) = -x_1 - x_2 + x_3 \leq 0 \end{array} \right.$$

解： (1) 目标函数是不是凸函数？

(2) $g_i(x)$ 是不是凸函数？

►关于凸函数的一些结论

定理： 设 $S \subset R^n$ 是非空凸集

(1)若 f 是 S 上的凸函数, $\alpha \geq 0$, 则 αf 是 S 上的凸函数;

(2)若 f_1, f_2 是 S 上的凸函数, $f_1 + f_2$ 是 S 上的凸函数。

定理： 设 $S \subset R^n$ 是非空凸集, f 是凸函数, $c \in R^1$,则集合

$H_S(f, c) = \{x \in S \mid f(x) \leq c\}$ 是凸集。

函数 f 在集合 S 上关于 c 的水平集

凸规划

$$(1) \min f(x) \quad s.t. \quad x \in D$$

其中 $f(x)$ 为凸函数, D 为非空凸集。

(2) 对于非线性规划(MP),

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \leq 0 \quad i=1, \dots, p \\ \quad \quad h_j(x) = 0 \quad j=1, \dots, q \end{cases}$$

若 $g_i(x)$ 皆为 R^n 上的凸函数, $h_j(x)$ 皆为线性函数, 并且 f 是 X 上的凸函数, 则 (MP) 是凸规划。

定理 凸规划的任一局部最优解都是它的整体最优解。

二次规划 $\min f(x) = \frac{1}{2}x^T Qx + q^T x + c$

$s.t. \quad Ax = b, \quad x \geq 0$

其中 $x \in R^n, Q \in R^{n \times n}, q \in R^n, c \in R^1,$

$A \in R^{m \times n}, b \in R^m$

$\nabla f(x) = Qx + q, \quad \nabla^2 f(x) = Q$

极小点的判定条件

必要条件：若 $f(x)$ 在开区域 D 内连续可微，且 $x^* \in D$ 为局部极值点，则 $\nabla f(x^*) = \mathbf{0}$ 。

充分条件：若 $f(x)$ 在开区域 D 内二阶连续可微， $x^* \in D$ ， $\nabla f(x^*) = \mathbf{0}$ ，且 $\nabla^2 f(x^*)$ 正定，则 x^* 为严格局部极小点。

$$f(x) = f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2} (x - x^*)^T \nabla^2 f(x^*) (x - x^*) + o(\|x - x^*\|^2)$$

$\nabla^2 f(x^*)$ 正定 \Rightarrow 函数在极小点附近的等值线为近似的同心椭圆。

正定二次函数 $f(x) = \frac{1}{2} x^T Q x + q^T x + c$ 有唯一极小点 $x^* = -Q^{-1}q$ 。

凸规划的主要性质

- 可行解集为凸集
- 最优解集为凸集(如果存在)
- 任何局部最优解也是全局最优解
- 若目标函数为严格凸函数，且最优解存在，则其最优解必唯一

第三节 一维搜索方法

在迭代法中确定搜索步长 t_k 需要一维搜索：

$$f(x^k + t_k p^k) = \min_t f(x^k + t p^k)$$

考虑一元函数极小化问题： $\min_{t \in R} f(t)$

方法：首先定出一个包含 $f(t)$ 的极小点的区间，然后不断缩小区间的长度，当区间充分小时，取其中的一点作为近似极小点。

如何确定一个包含极小点的区间？

进退法：从一点出发，按一定的步长寻找函数值呈现“高 - 低 - 高”的三点，若一个方向不成功，就退回来，然后沿相反方向寻找。


黄金分割法（0.618 法）

二次逼近法（抛物线插值）

4、Newton法

进退法: 从一点出发, 按一定的步长寻找函数值呈现
“高 - 低 - 高” 的三点, 若一个方向不成功,
就退回来, 然后沿相反方向寻找。

任取初始点 t_0 , 计算 $f(t_0)$, 取步长 $h > 0$, 计算 $f(t_0 + h)$,
若 $f(t_0) > f(t_0 + h)$, 令 $t_1 = t_0 + h$, $h = 2h$, 计算 $f(t_1 + h)$,
若 $f(t_1) > f(t_1 + h)$, 令 $t_2 = t_1 + h$, $h = 2h$, 计算 $f(t_2 + h)$,
如此继续下去, 直到对某个 k 得到 $f(t_k) < f(t_k + h)$,
此时得到一个包含极小点的区间 $[t_{k-1}, t_k + h]$;




若一开始 $f(t_0) < f(t_0 + h)$,

令 $t_1 = t_0$, $t_0 = t_0 + h$, $h = 2h$, 计算 $f(t_1 - h)$,

若 $f(t_1 - h) < f(t_1)$, 则令 $t_2 = t_1 - h$, $h = 2h$, 计算 $f(t_2 - h)$,

如此继续下去, 直到对某个 k 得到 $f(t_k - h) > f(t_k)$,

此时得到一个包含极小点的区间 $[t_k - h, t_k]$ 。




黄金分割法（0.618 法）

解一元函数极小化问题 $\min_{a \leq t \leq b} f(t)$

假设： $f(t)$ 在 $[a, b]$ 上是单谷函数，即 $f(t)$ 在 $[a, b]$ 上有唯一极小点（设为 t^* ）且

$a \leq t_1 < t_2 \leq t^*$ 时， $f(t_1) > f(t_2)$ ；


$t^* \leq t_1 < t_2 \leq b$ 时， $f(t_1) < f(t_2)$ 。



在 $[a, b]$ 上任取两点 $t_1 < t_2$,
计算 $f(t_1)$ 、 $f(t_2)$, 则

若 $f(t_1) < f(t_2)$, 则 $t^* \in [a, t_2]$;

若 $f(t_1) \geq f(t_2)$, 则 $t^* \in [t_1, b]$,



即通过比较 $f(t_1)$ 、 $f(t_2)$, 可将 t^* 的搜索区间从 $[a, b]$ 缩短为 $[a, t_2]$ 或 $[t_1, b]$ 。为了进一步缩短搜索区间, 需比较 $[a, t_2]$ 或 $[t_1, b]$ 中两点的函数值。

由于 $t_1 \in [a, t_2]$, $t_2 \in [t_1, b]$, 即保留下来的区间中总 含有一个已计算过函数值 的点, 因此要进一步缩 短搜索区间, 只需再取一点计 算函数值即可。

n 次函数值计算可使搜索区间缩短 $n - 1$ 次。



下面推导黄金分割法如何选取计算点 t_1 、 t_2 。

两个条件：

(1) 由于在比较 $f(t_1)$ 和 $f(t_2)$ 之前不知道 $[a, t_2]$ 和 $[t_1, b]$ 中哪一个将保留下来，因此限定 t_1, t_2 为 $[a, b]$ 中对称的计算点，即满足条件 $t_2 - a = b - t_1$ 。

(2) 希望每次迭代保持相同 的区间缩短率，

$$\text{当前迭代的区间缩短率 } \frac{t_2 - a}{b - a} = \frac{b - t_1}{b - a} = \omega$$

$$\text{即 } t_1 = b - \omega(b - a), \quad t_2 = a + \omega(b - a). \quad (1)$$

不妨设当前迭代后保留 下来的区间为 $[a, t_2]$,

下一步迭代的计算点为 $t'_1 < t'_2$ (其中一个为 t_1),
则下一步迭代的区间缩 短率为



$$\frac{t'_2 - a}{t_2 - a} = \frac{t_2 - t'_1}{t_2 - a} = \omega$$

所以 $t'_2 - a = t_2 - t'_1 = \omega(t_2 - a) = \omega^2(b - a)$.

若 $t'_1 = t_1$, 则 $t_2 - t_1 = \omega^2(b - a)$,

而由 (1), $t_2 - t_1 = (2\omega - 1)(b - a)$,

因此 $\omega^2 = 2\omega - 1$, $\omega = 1$, 但这不可能 .

设 $t'_2 = t_1$, 则 $t_1 - a = \omega^2(b - a)$,

而由 (1), $t_1 - a = (1 - \omega)(b - a)$,

所以 $\omega^2 = 1 - \omega$, $\omega = \frac{\sqrt{5}-1}{2} \approx 0.618$.

对保留下来的区间为 $[t_1, b]$ 的情形可类似考虑,
但此时应 $t'_1 = t_2$.



黄金分割法的计算步骤:

(1) 给定初始区间 $[a, b]$, 精度要求 $\varepsilon > 0$.

(2) 取初始计算点

$$t_1 = a + 0.382(b - a) = b - 0.618(b - a),$$

$$t_2 = a + 0.618(b - a) = b - 0.382(b - a),$$

计算 $f(t_1)$ 、 $f(t_2)$ 。

(3) 若 $f(t_1) < f(t_2)$, 转 (4), 否则转 (5).

(4) 若 $t_2 - a < \varepsilon$, 停止, 输出 t_1 ; 否则, 令

$$b = t_2, \quad t_2 = t_1, \quad t_1 = a + 0.382(b - a) = b - 0.618(b - a),$$

计算 $f(t_1)$, 转 (3)。

(5) 若 $b - t_1 < \varepsilon$, 停止, 输出 t_2 ; 否则, 令

$$a = t_1, \quad t_1 = t_2, \quad t_2 = a + 0.618(b - a) = b - 0.382(b - a),$$

计算 $f(t_2)$, 转 (3)。



黄金分割法的迭代效果：

每次迭代的区间缩短率 为 $\frac{\sqrt{5}-1}{2}$ ，

n 次迭代（计算 $n+1$ 个点的函数值）后区间 缩短为


初始区间长度的 $\left(\frac{\sqrt{5}-1}{2}\right)^n$ 倍。

其它试探点算法：Fibonacci 算法




➤假定：已经确定了单谷区间[a,b]

$$\left. \begin{array}{l} \min_{t \geq 0} \varphi(t) \\ \min_{0 \leq t \leq t_{\max}} \varphi(t) \end{array} \right\} \longrightarrow \min_{a \leq t \leq b} \varphi(t)$$




新搜索区间为[a, t_2]



新搜索区间为[t_1 , b]

➤ 区间缩小比例的确定:



区间缩短比例为 $(t_2 - a) / (b - a)$ 缩短比例为 $(b - t_1) / (b - a)$

缩短比例满足:

每次插入搜索点使得两个区间 $[a, t_2]$ 和 $[t_1, b]$ 相等;

每次迭代都以相等的比例缩小区间。

缩短比例 $\omega = \frac{\sqrt{5}-1}{2} \approx 0.618 \dots$ 0.618法

第 1 步 确定单谷区间 $[a,b]$ ，给定最后区间精度 $\varepsilon > 0$ ；

第 2 步 计算最初两个探索点

$$t_1 = a + 0.382(b - a) = b - 0.618(b - a)$$

$$t_2 = a + 0.618(b - a)$$

并计算 $\varphi_1 = \varphi(t_1)$ ， $\varphi_2 = \varphi(t_2)$ ；

第 3 步 若 $\varphi_1 \leq \varphi_2$ ，转第 4 步。否则转第 5 步；

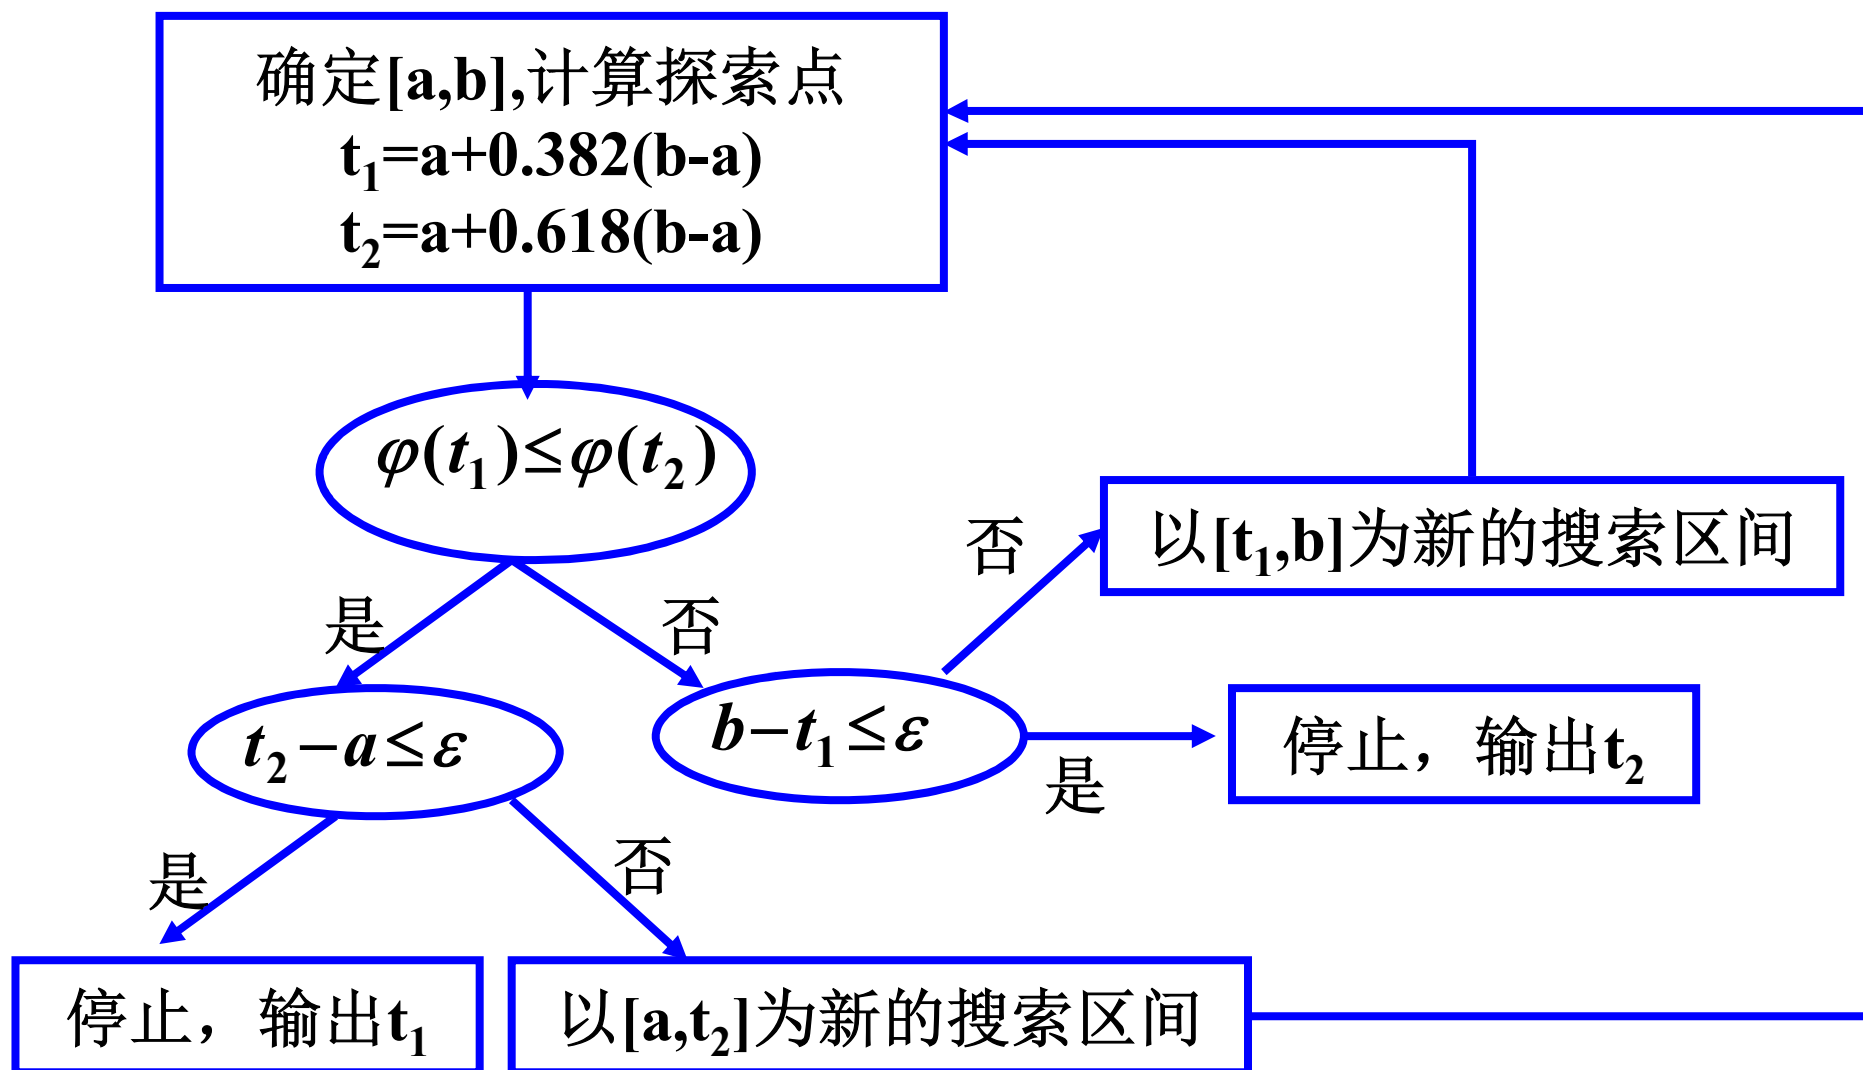
第 4 步 若 $t_2 - a \leq \varepsilon$ ，停止迭代，输出 t_1 。否则令 $b := t_2$ ，

$t_2 := t_1$ ， $t_1 := b - 0.618(b - a)$ ， $\varphi_2 := \varphi_1$ ，计算 $\varphi_1 = \varphi(t_1)$ ，转第 3 步；

第 5 步 若 $b - t_1 \leq \varepsilon$ ，停止迭代，输出 t_2 。否则令 $a := t_1$ ，

$t_1 := t_2$ ， $t_2 := a + 0.618(b - a)$ ， $\varphi_1 := \varphi_2$ ，计算 $\varphi_2 = \varphi(t_2)$ ，转第 3 步。

➤0.618法解题步骤:



➤例：求解 $\min_{t \geq 0} \varphi(t) = t^3 - 2t + 1$

其中单谷区间 $[0,3]$,精度0.5

解：


1、第一轮：

$$t_1 = 1.146, t_2 = 1.854$$

$$\varphi(t_1) = 0.2131,$$

$$\varphi(t_2) = 3.6648$$

$$t_2 - 0 > 0.5$$



2、第二轮:

$$t_2=1.146, t_1=0.708$$

$$\varphi(t_1)=-0.0611$$

$$\varphi(t_2)=0.2131$$

$$t_2-0=1.146>0.5$$



3、第三轮:

$$t_1=0.438, t_2=0.708$$

$$\varphi(t_2)=-0.0611$$

$$\varphi(t_1)=0.2082$$

$$b-t_1=1.146-0.438>0.5$$




4、第四轮：

$$t_2=0.876, t_1=0.708$$

$$\varphi(t_1)=-0.0611$$

$$\varphi(t_2)=-0.0798$$

$$b-t_1=1.146-0.708<0.5$$



输出： $t^*=t_2=0.876$ 为最优解，最优值为-0.0798

课下练习： 仔细分析上述迭代过程，体会0.618法的实质。

例. 用 0.618 法计算 $f(t) = (t-1)^2$ 在 $[0, 3]$ 上的极小点。

解. 计算点 $t_1 = 0 + 0.382 \times (3 - 0) = 1.146$

$$t_2 = 0 + 0.618 \times (3 - 0) = 1.854$$

$$f(t_1) = 0.146^2 = 0.0213, \quad f(t_2) = 0.854^2 = 0.7293$$

$f(t_1) < f(t_2)$, 新的搜索区间 $[0, 1.854]$

新的计算点 $t_2 = t_1 = 1.146$, $f(t_2) = 0.0213$

$$t_1 = 0 + 0.382 \times (1.854 - 0) = 0.708$$

$$f(t_1) = (0.708 - 1)^2 = 0.0851 > f(t_2)$$

新的搜索区间 $[0.708, 1.854]$


新的计算点 $t_1 = t_2 = 1.146$, $f(t_1) = 0.0213$

$$t_2 = 0.708 + 0.618 \times (1.854 - 0.708) = 1.416$$



二次逼近法（抛物线插值）

思想 在极小点附近，用二次三项式 $\varphi(t)$ 逼近目标函数 $f(t)$ ，令 $\varphi(t)$ 与 $f(t)$ 在三点 $t_1 < t_2 < t_3$ 处有相同的函数值，并假设 $f(t_1) > f(t_2)$, $f(t_2) < f(t_3)$.



如何计算函数 $\varphi(t)$?

设 $\varphi(t) = a + bt + ct^2$, 则

$$\varphi(t_1) = a + bt_1 + ct_1^2 = f(t_1)$$

$$\varphi(t_2) = a + bt_2 + ct_2^2 = f(t_2)$$

$$\varphi(t_3) = a + bt_3 + ct_3^2 = f(t_3)$$

解上述方程组, 可得逼近函数 $\varphi(t)$ 的系数 b 和 c .

再求函数 $\varphi(t)$ 的极小点, 令

$$\varphi'(t) = b + 2ct = 0,$$

解得 $\bar{t} = -\frac{b}{2c}.$

以 \bar{t} 作为 $f(t)$ 的极小点的估计值。



抛物线插值算法步骤:

(1) 给定初始区间 $[t_1, t_3]$, 设 $f(t_1) > f(t_2), f(t_2) < f(t_3)$.

令 $k := 1, \bar{t}^{(0)} = t_2$, 给定精度 ε .

(2) 设 $\varphi(t) = a + bt + ct^2$. 令 $\varphi(t_i) = f(t_i), i = 1, 2, 3$, 解出

系数 a, b, c 及 $\varphi(t)$ 的极小点 $\bar{t}^{(k)} = -\frac{b}{2c}$.

若 $|f(\bar{t}^{(k)}) - f(\bar{t}^{(k-1)})| < \varepsilon$, 则算法停止, 否则转 (3).

(3) 从 t_1, t_2, t_3 和 $\bar{t}^{(k)}$ 中选择 $f(t)$ 的函数值最小的点 及其左、右两点, 重新标记为 t_1, t_2, t_3 . 令 $k := k + 1$, 转 (2).



4、Newton法

考虑 $\min \varphi(t)$, 其中 $\varphi(t)$ 二次可微, $\varphi''(t) \neq 0$

➤ Newton法基本思想:

用探索点 t_k 处的二阶Taylor展开式近似代替目标函数, 以展开式的最小点为新的探索点。

展开式: $g(t) = \varphi(t_k) + \varphi'(t_k)(t - t_k) + \frac{1}{2}\varphi''(t_k)(t - t_k)^2$

$g(t)$ 的最小点即导数为0的点, 求导得:

$$t_{k+1} = t_k - \frac{\varphi'(t_k)}{\varphi''(t_k)}$$

Newton法

$$\min \quad \varphi(t)$$

其中 $\varphi(t)$ 是二次可微的，且 $\varphi''(t) \neq 0$ 。

第1步 给定初始点 t_1 ， $\varepsilon > 0$ ， $k := 1$ ；

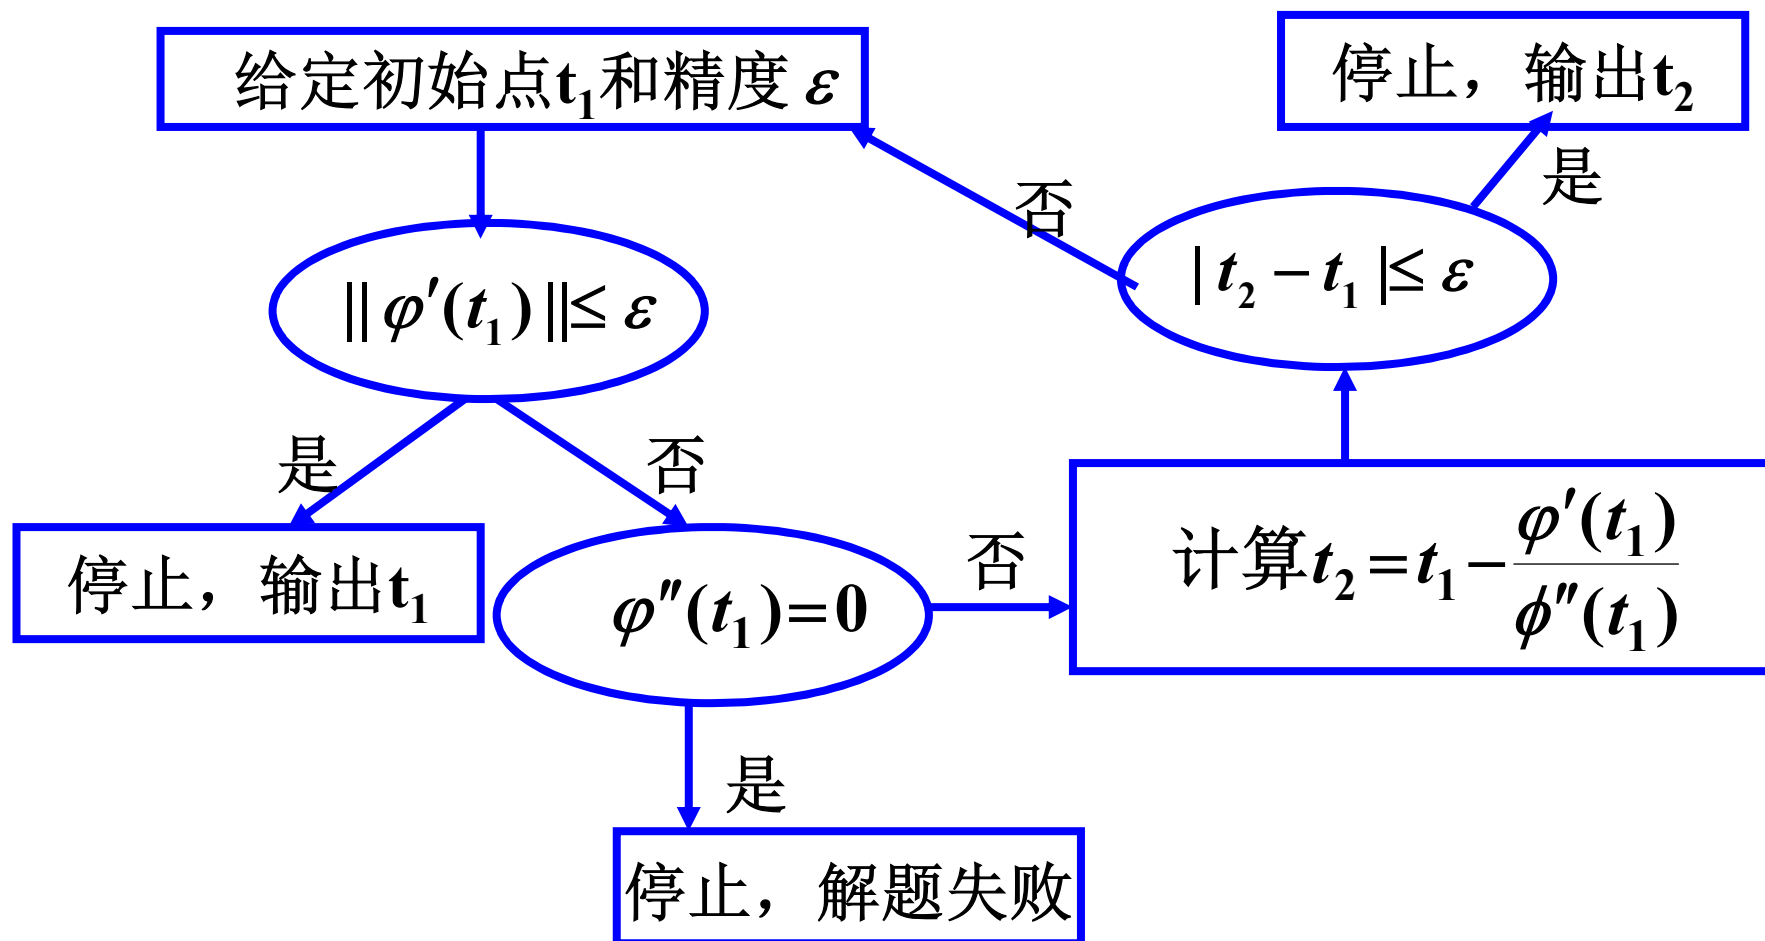
第2步 如果 $|\varphi'(t_k)| < \varepsilon$ ，停止迭代，输出 t_k 。否则，当 $\varphi''(t_k) = 0$ 时，停止，解题失败；当 $\varphi''(t_k) \neq 0$ 时，转下一步；

第3步 计算 $t_{k+1} = t_k - \frac{\varphi'(t_k)}{\varphi''(t_k)}$ ，如果 $|t_{k+1} - t_k| < \varepsilon$ ，停止迭代，输出 t_{k+1} 。否则

$k := k + 1$ ，转第2步。



► 解题步骤:



➤例： 求解 $\min \varphi(t) = \int_0^t \arctan x dx$

解： 取 $t_1=1$,计算:

$$\varphi'(t) = \arctan t, \varphi''(t) = \frac{1}{1+t^2}$$

迭代过程如下表:

k	t_k	$\varphi'(t_k)$	$\varphi''(t_k)$
1	1	0.7854	2
2	-0.5708	-0.5178	1.3258
3	0.1169	0.1163	1.137
4	-0.001061		

$$t_{k+1} = t_k - \frac{\varphi'(t_k)}{\varphi''(t_k)}$$

第四节 无约束最优化方法

➤ 本节课讨论n元函数的无约束非线性规划问题：

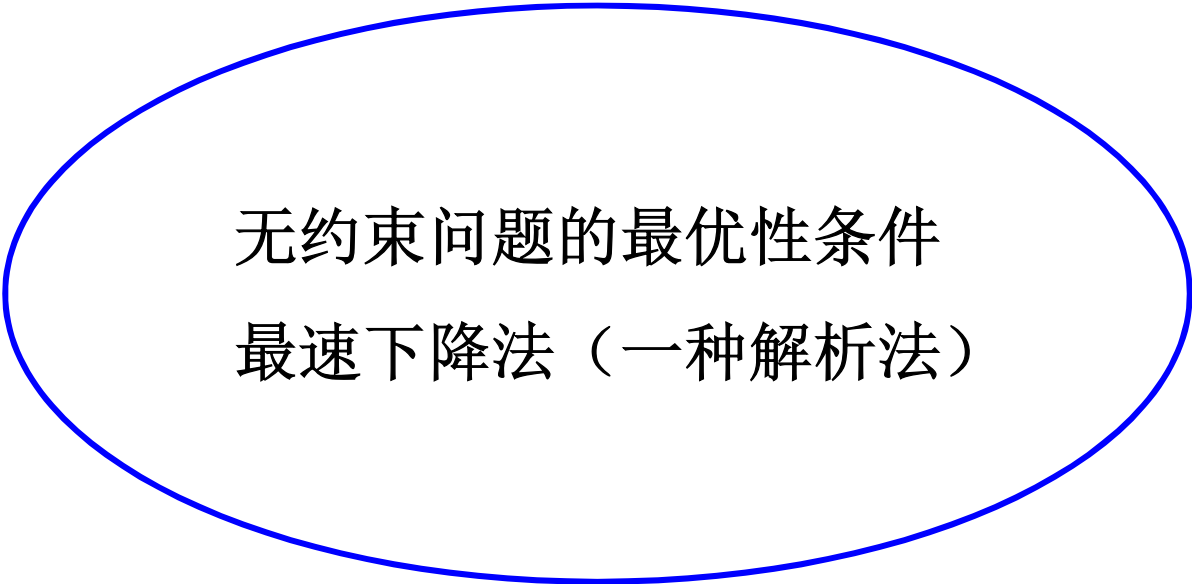
$$\min f(x), \text{其中 } x = (x_1, x_2, \dots, x_n)^T \in R^n$$

➤ 求解此类模型 (UMP) 的方法称为无约束最优化方法。

➤ 无约束最优化方法通常有两类：

解析法：要使用导数的方法；

直接法：无须考虑函数是否可导，直接使用函数值。



无约束问题的最优性条件
最速下降法（一种解析法）

1、无约束问题的最优性条件

定理1 设 $f:R^n \rightarrow R$ 在点 $\bar{x} \in R^n$ 处可微, 若存在 $p \in R^n$, 使

$$\nabla f(\bar{x})^T p < 0$$

则向量 p 是 f 在点 \bar{x} 处的下降方向

定理2 设 f 在点 $x^* \in R^n$ 可微, 若 x^* 是 $\min f(x)$ 的局部最优解

$$\text{则 } \nabla f(x^*) = 0$$

注: 梯度为0的点称为函数的**驻点**。

驻点可能是极小点, 也可能是极大点, 也可能即不是极大也不是极小, 这时称为函数的**鞍点**。

定理2说明: UMP问题的局部最优解必是目标函数的驻点。

定理3 设 f 在点 $x^* \in R^n$ 处的Hesse矩阵 $\nabla^2 f(x^*)$ 存在,

若 $\nabla f(x^*)=0$,并且 $\nabla^2 f(x^*)$ 正定

则 x^* 是 $\min f(x)$ 的严格局部最优解

定理4 设 $f: R^n \rightarrow R^1, x^* \in R^n, f$ 是 R^n 上的可微凸函数

若 $\nabla f(x^*)=0$, 则

则 x^* 是 $\min f(x)$ 的整体最优解

例 求无约束非线性规划问题

$$\min f(x_1, x_2, x_3) = x_1^2 + 4x_2^2 + x_3^2 - 2x_1$$

解：

- 1、先求出目标函数的全部驻点；
- 2、利用充分条件判断驻点是不是最优点。

2. 最速下降法（梯度法）

问题： $\min_{x \in R^n} f(x)$ ，其中 $f(x)$ 一阶连续可微。

思想：取目标函数值在当前点 x^k 处下降最快的方向（即负梯度方向） $-\nabla f(x^k)$ 为搜索方向；

迭代公式： $x^{k+1} = x^k - t_k \nabla f(x^k)$ ，其中步长 t_k 由精确一维搜索 $\min_{t \geq 0} f(x^k - t \nabla f(x^k))$ 确定。



➤关于梯度的复习:

梯度是一个向量。n元函数 $f(x_1, x_2, \dots, x_n)$ 在某点 x 处的梯度为:

$$\left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n}\right)^T$$

梯度的方向与函数 f 的等值线的一个法线方向相同, 从较低的等值线指向较高的等值线。

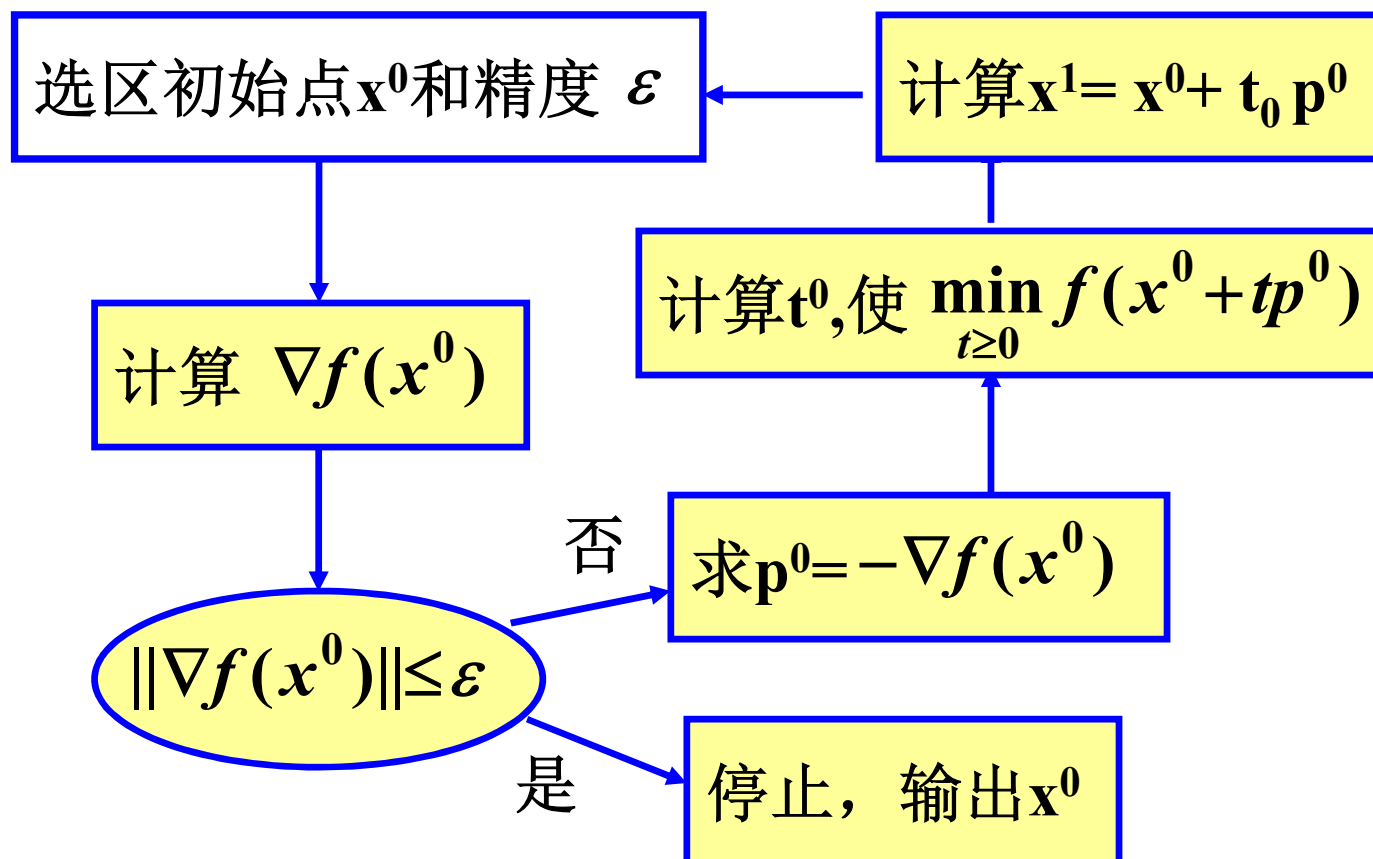
梯度的方向就是函数 f 的值增加最快的方向, 其相反方向就是函数值降低最快的方向。

➤最速下降法又称为**梯度法**，由**Cauchy**于**1847**年给出。

➤最速下降法解决的是**具有连续可微的目标函数**的**UMP**问题。

➤最速下降法的基本思想：从当前点 \mathbf{x}^k 出发寻找使得目标函数下降最快的方向，即**负梯度方向**。

➤ 最速下降法计算步骤:



例. $\min f(x) = (x_1)^2 + 2(x_2)^2$, 初始点 $x^0 = (1, 1)^T$.

解. $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 4x_2 \end{pmatrix} \quad \nabla f(x^0) = \begin{pmatrix} 2 \\ 4 \end{pmatrix}$

$$x^1 = x^0 - t \nabla f(x^0) = \begin{pmatrix} 1 - 2t \\ 1 - 4t \end{pmatrix}$$

$$f(x^1) = (1 - 2t)^2 + 2(1 - 4t)^2 = 36t^2 - 20t + 3$$

$$t = \frac{5}{18} \text{ 时, } f(x^1) \text{ 最小, } x^1 = \begin{pmatrix} \frac{4}{9} \\ -\frac{1}{9} \end{pmatrix}$$

$$\nabla f(x^1) = \begin{pmatrix} \frac{8}{9} \\ -\frac{4}{9} \end{pmatrix} \quad \dots$$



性质： 在最速下降算法中，若 步长由精确一维搜索确定，则 $\nabla f(x^{k+1})^T \nabla f(x^k) = 0$ 。


证明： 设 $\varphi(t) = f(x^k - t \nabla f(x^k))$ 。由于搜索步长 t_k 使得 $\varphi(t)$ 达到最小，所以

$$\varphi'(t_k) = -\nabla f(x^k - t_k \nabla f(x^k))^T \nabla f(x^k) = 0$$

$$\text{即 } \nabla f(x^{k+1})^T \nabla f(x^k) = 0。$$



注：在极小点附近，目标函数可用二次函数近似，因此等值面近似为椭球面，上述性质说明最速下降法的搜索路径呈直角锯齿状：



最速下降方向只是目标函数的局部下降最快方向，最速下降算法收敛速度慢，但具有整体收敛性。



近似最佳步长:

若 $f(x)$ 二阶连续可微, 则

$$f(x^k - t \nabla f(x^k)) \approx f(x^k) - t \nabla f(x^k)^T \nabla f(x^k) + \frac{1}{2} t^2 \nabla f(x^k)^T \nabla^2 f(x^k) \nabla f(x^k)$$

右端为二次函数,

$$t = \frac{\nabla f(x^k)^T \nabla f(x^k)}{\nabla f(x^k)^T \nabla^2 f(x^k) \nabla f(x^k)} \quad \text{时达到最小。}$$



梯度法(最速下降法)步骤:

Step1: 选取初始点 x^0 , 给定终止误差 $\varepsilon > 0$, 令 $k = 0$;

Step2: 计算梯度向量 $\nabla f(x^k)$.

若 $\|\nabla f(x^k)\| < \varepsilon$, 终止迭代计算, 输出最优解 $x^* = x^k$;

否则, 转**Step3**。

Step3: 构造最速下降方向。令 $d^k = -\nabla f(x^k)$

Step4: 进行一维搜索。求 t_k , 使得

$$f(x^k + t_k d^k) = \min_{t > 0} f(x^k + t d^k)$$

令 $x^{k+1} = x^k + t_k d^k, k = k + 1$, 转**Step2**。

3. 共轭方向法

共轭方向：设 A 是 n 阶对称正定阵，对于 R^n 中的两个非零向量 p^1 和 p^2 ，若 $(p^1)^T A p^2 = 0$ ，则称 p^1 和 p^2 关于 A 共轭。

若非零向量组 p^1, p^2, \dots, p^k 中的向量两两关于 A 共轭，则称该向量组关于 A 共轭。

注：共轭是正交的推广。

性质：共轭向量组一定线性无关。

正定二次函数的共轭方向法：

$$\min f(x) = \frac{1}{2} x^T A x + b^T x + c, \quad \text{其中 } A \text{ 正定。}$$



取 n 个 A 共轭方向 p^0, p^1, \dots, p^{n-1} , 依次以它们为搜索方向进行迭代, 即

$$x^{k+1} = x^k + t_k p^k, \quad k = 0, 1, \dots, n-1$$

$$t_k : \min_{t \geq 0} f(x^k + t p^k)$$

性质: 共轭方向法用于正定二次函数, 则至多经过 n 次迭代即得极小点。

问题: 如何选择一组共轭方向?

共轭梯度法:

以已知迭代点处的梯度方向为基础产生共轭方向。

在初始点 x^0 , 取 $p^0 = -\nabla f(x^0)$



在 x^1 , 设 $p^1 = -\nabla f(x^1) + \alpha_0 p^0$

p^1 与 p^0 关于 A 共轭, 即 $(-\nabla f(x^1) + \alpha_0 p^0)^T A p^0 = 0$

$$\therefore \alpha_0 = \frac{\nabla f(x^1)^T A p^0}{(p^0)^T A p^0}$$

一般地, 若已得 A 共轭方向 p^0, p^1, \dots, p^k , 可设

$$p^{k+1} = -\nabla f(x^{k+1}) + \sum_{i=0}^k \alpha_i p^i$$

可证: 欲使 $(p^{k+1})^T A p^j = 0$ ($j = 0, 1, \dots, k$), 必有

$$\alpha_0 = \alpha_1 = \dots = \alpha_{k-1} = 0.$$

因此

$$p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k, \quad \alpha_k = \frac{\nabla f(x^{k+1})^T A p^k}{(p^k)^T A p^k}$$



共轭梯度法的搜索方向：

$$p^0 = -\nabla f(x^0)$$

$$p^{k+1} = -\nabla f(x^{k+1}) + \alpha_k p^k$$

$$\alpha_k = \frac{\nabla f(x^{k+1})^T A p^k}{(p^k)^T A p^k}, \quad k = 0, 1, \dots, n-1$$

共轭梯度法用于正定二次函数时具有性质：

(1) 若 $i \neq j$ ，则 $\nabla f(x^i)^T \nabla f(x^j) = 0$ ；

$$(2) t_k = -\frac{\nabla f(x^k)^T p^k}{(p^k)^T A p^k}.$$

为了将共轭梯度法用于非二次函数，需消去公式中的 A 。



$$\because \nabla f(x) = Ax + b ,$$

$$\therefore \nabla f(x^{k+1}) - \nabla f(x^k) = A(x^{k+1} - x^k) = t_k A p^k$$

在 α_k 的表达式的分子、分母 同乘以 t_k , 则

$$\begin{aligned} \alpha_k &= \frac{\nabla f(x^{k+1})^T (t_k A p^k)}{(p^k)^T (t_k A p^k)} = \frac{\nabla f(x^{k+1})^T (\nabla f(x^{k+1}) - \nabla f(x^k))}{(p^k)^T (\nabla f(x^{k+1}) - \nabla f(x^k))} \\ &= \frac{\nabla f(x^{k+1})^T \nabla f(x^{k+1})}{-(p^k)^T \nabla f(x^k)} \\ &= \frac{\nabla f(x^{k+1})^T \nabla f(x^{k+1})}{-(-\nabla f(x^k) + \alpha_{k-1} p^{k-1})^T \nabla f(x^k)} \\ &= \frac{\nabla f(x^{k+1})^T \nabla f(x^{k+1})}{\nabla f(x^k)^T \nabla f(x^k)} = \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2} \end{aligned}$$



5. 牛顿法

问题: $\min_{x \in R^n} f(x)$, 其中 $f(x)$ 二阶连续可微.

在 x^k 附近, $f(x)$ 有近似式:

$$f(x) \approx g(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$

若 $(\nabla^2 f(x^k))^{-1}$ 存在, 取 $g(x)$ 的极小点为 x^{k+1} , 则

$$\nabla g(x^{k+1}) = \nabla f(x^k) + \nabla^2 f(x^k)(x^{k+1} - x^k) = 0$$

$$\therefore x^{k+1} = x^k - (\nabla^2 f(x^k))^{-1} \nabla f(x^k) \quad \text{牛顿法的迭代公式}$$

$$p^k = -(\nabla^2 f(x^k))^{-1} \nabla f(x^k) \quad \text{牛顿方向}$$



几点说明:

(1) 若 $f(x)$ 为正定二次函数, 则牛顿法只需一步迭代即得极小点, 因为此时有 $f(x) = g(x)$, 所以

$$\nabla f(x^1) = \nabla g(x^1) = 0.$$

(2) 牛顿法具有二阶收敛速率, 但要求初始点选在极小点附近。

(3) $(\nabla^2 f(x^k))^{-1}$ 的存在性不易保证, 即使存在, 也不易计算。

(4) 由于 $f(x) \approx g(x)$ 仅在 x^k 附近成立, 因此 $f(x^{k+1}) \leq f(x^k)$ 不一定成立, 改进的一个途径是沿 $-(\nabla^2 f(x^k))^{-1} \nabla f(x^k)$ 线性搜索确定 x^{k+1} .

