

# 第八章 约束极值问题

➤ 本章讨论约束非线性规划问题MP

$$\begin{cases} \min & f(x) \\ s.t. & g_i(x) \geq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

其中,  $x=(x_1, x_2, \dots, x_n)^T$ ,  $f(x), g_i(x), h_j(x)$  为  $x$  的实值函数

➤ 求解此类模型(MP)的方法称为约束最优化方法。

➤本课程内容:

约束问题的最优性条件

制约函数法

# 1、约束最优化问题的最优性条件

➤ 对于 MP 问题:

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

$$\text{设 } x^* \in X = \left\{ x \in R^n \left| \begin{array}{l} g_i(x) \geq 0, i = 1, \dots, p \\ h_j(x) = 0, j = 1, \dots, q \end{array} \right. \right\}$$

$$\text{则 } g_i(x^*) \geq 0, i = 1, \dots, p, \quad h_j(x^*) = 0, j = 1, \dots, q$$

$g_i(x^*) \geq 0, i = 1, \dots, p$  有两种情况:

1、  $g_i(x^*) > 0$  若  $x^*$  有变化, 则约束条件可能没有破坏

2、  $g_i(x^*) = 0$  若  $x^*$  有变化, 则约束条件一定被破坏

使  $g_i(x^*) = 0$  的约束条件  $g_i(x) \geq 0$  称为  $x^*$  的积极约束

令  $J$  表示 MP 的全部等式约束的下标集合, 即  $J = \{1, 2, \dots, q\}$ ,

$I$  表示 MP 的全部不等式约束的下标集合, 即  $I = \{1, 2, \dots, p\}$

记  $I(x^*) = \{i | g_i(x^*) = 0, i \in I\}$

$x^*$  的积极约束的下标集合

性质：若  $p$  为  $x$  处的可行方向，则  $\forall j \in I(x)$  有

$$\nabla g_j(x)^T p \geq 0.$$

反之，对于方向  $p$ ，


若  $\forall j \in I(x)$  有  $\nabla g_j(x)^T p > 0$ ，  
则  $p$  必是  $x$  处的可行方向。

因为对于充分小的  $t > 0$ ，有

若  $j \notin I(x)$ ，即  $g_j(x) > 0$ ，

则  $g_j(x + tp) > 0$ ；

若  $j \in I(x)$ ，则  $g_j(x + tp) = g_j(x) + t \nabla g_j(x)^T p + o(t)$   
$$= t \nabla g_j(x)^T p + o(t)$$
$$> 0.$$



另外, 若  $\nabla f(x)^T p < 0$ , 则  $p$  为  $x$  处的下降方向, 因此有

定理: 若  $x^*$  为极小点, 则不存在方向  $p$  使得


$$\nabla f(x^*)^T p < 0 \text{ 且 } \nabla g_j(x^*)^T p > 0, j \in I(x^*).$$

**Kuhn-Tucker 条件** (极值点的必要条件)

设  $x^*$  为一个局部极小点.

(1) 若  $I(x^*) = \{i\}$ , 即只有一个积极约束  $g_i(x^*) \geq 0$ .


则  $\nabla g_i(x^*)$  与  $-\nabla f(x^*)$   
共线且方向相反,  
否则存在一个  
可行下降方向  $p$ .



(3) 一般地, 设  $\{\nabla g_j(x^*) | j \in I(x^*)\}$  线性无关, 则存在实数  $\lambda_j \geq 0$  ( $j \in I(x^*)$ ) 使得

$$\nabla f(x^*) = \sum_{j \in I(x^*)} \lambda_j \nabla g_j(x^*)$$

即  $\nabla f(x^*)$  在  $\nabla g_j(x^*)$  ( $j \in I(x^*)$ ) 张成的凸锥内.



对于  $\begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \geq 0 \end{cases}$ , 若  $x^*$  是其局部最优解, 则

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) = 0 \\ \lambda_i \geq 0, i \in I(x^*) \end{cases}$$

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

(4) 由于等式约束  $h_i(x) = 0$  可用两个不等式约束  $h_i(x) \geq 0$  和  $-h_i(x) \geq 0$  代替, 而且二者都是积极约束, 因此有正数  $\lambda_j$ 、 $\mu_i^+$ 、 $\mu_i^-$  使得

$$\begin{aligned} \nabla f(x^*) = & \sum_{j \in I(x^*)} \lambda_j \nabla g_j(x^*) \\ & + \sum_{i=1}^m (\mu_i^+ \nabla h_i(x^*) - \mu_i^- \nabla h_i(x^*)) \end{aligned}$$

令  $\mu_i = \mu_i^+ - \mu_i^-$ , 则

$$\nabla f(x^*) = \sum_{j \in I(x^*)} \lambda_j \nabla g_j(x^*) + \sum_{i=1}^m \mu_i \nabla h_i(x^*)$$



**Kuhn–Tucker (K–T) 条件:**

若  $x^*$  是局部极小点,  $f(x)$ 、 $h_i(x)$ 、 $g_j(x)$  在  $x^*$  可微,  
 $\nabla h_i(x^*)$ 、 $\nabla g_j(x^*)$  ( $j \in I(x^*)$ ) 线性无关, 则存在一组  
实数  $\mu_i$ 、 $\lambda_j$  满足

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) - \sum_{j \in J} \mu_j \nabla h_j(x^*) = 0 \\ \lambda_i \geq 0, i \in I(x^*) \end{cases}$$

## KT条件的说明:

1、 $\nabla g_i(x), i \in I(x^*), \nabla h_j(x), j \in J$  线性无关, 称为约束规范条件。

2、称下述表达式为MP的Kuhn-Tucker条件, 简称K-T条件

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) - \sum_{j \in J} \mu_j \nabla h_j(x^*) = 0 \\ \lambda_i \geq 0, i \in I(x^*) \end{cases}$$

满足K-T条件的点称为MP的K-T点, 定理说明MP的局部最优解一定是MP的K-T点。

为了求出MP的最优解, 可以先找出MP的K-T点, 再做进一步的判断。

### 3、特例1

对于  $\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \end{cases}$ , 若  $x^*$  是其局部最优解, 则

$$\exists \text{实数 } \lambda_i^*, i \in I(x^*) \text{ 使得 } \begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*) = 0 \\ \lambda_i^* \geq 0, i \in I(x^*) \end{cases}$$

$$-\nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*) \quad \lambda_i^* \geq 0$$

## 4、特例2

对于  $\begin{cases} \min & f(x) \\ \text{s.t.} & h_j(x)=0 \end{cases}$ , 若  $x^*$  是局部最优解, 则

$$\exists \mu_j^*, j \in J \text{ 使得: } \nabla f(x^*) - \sum_{j \in J} \mu_j^* \nabla h_j(x^*) = 0$$

$$\nabla f(x^*) = \sum_{j \in J} \mu_j^* \nabla h_j(x^*)$$

若  $x^*$  局部最优解, 则  $-\nabla f(x^*)$  落在由向量  $\nabla h_j(x^*), j \in J$  生成的空间中。

## 5、实例说明

$$\left\{ \begin{array}{l} \min f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 2)^2 \\ s.t. \quad g_1(x) = x_1 + x_2 - 2 \leq 0 \\ \quad \quad g_2(x) = -x_1 \leq 0 \\ \quad \quad g_3(x) = -x_2 \leq 0 \\ \quad \quad h_1(x) = -x_1 + x_2 - 1 = 0 \end{array} \right.$$

定理表明：若 $(x_1, x_2)^T$ 是局部最优解，若 $g_1$ 和 $g_2$ 为积极约束，则：

$$\left\{ \begin{array}{l} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) - \sum_{j \in J} \mu_j \nabla h_j(x^*) = 0 \\ \lambda_i \geq 0, i \in I(x^*) \end{array} \right.$$

不知道哪些是积极约束怎么办？



$$\left\{ \begin{array}{l} \begin{pmatrix} 2(x_1 - 1) \\ 2(x_2 - 1) \end{pmatrix} + \lambda_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} = 0 \\ \lambda_1, \lambda_2 \geq 0 \end{array} \right.$$

## 改进： 引入互补松紧条件

➤ 对于 MP 问题：

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

记  $I(x^*) = \{i | g_i(x^*) = 0, i \in I\}$   $x^*$  的积极约束的下标集合

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) - \sum_{j \in J} \mu_j \nabla h_j(x^*) = 0 \\ \lambda_i \geq 0, i \in I(x^*) \end{cases} \quad i \notin I(x^*) \text{ 怎么办?}$$

$i \notin I(x^*)$ , 则  $g_i(x) > 0$  此时引入  $\lambda_i = 0$ , 则也有  $\lambda_i g_i(x) = 0$

$i \in I(x^*)$ , 则  $g_i(x) = 0$ , 此时显然  $\lambda_i g_i(x) = 0$

从而  $\forall i \in I$ , 都有  $\lambda_i g_i(x) = 0$  互补松紧条件

**Kuhn–Tucker (K–T) 条件:**

若  $x^*$  是局部极小点,  $f(x)$ 、 $h_i(x)$ 、 $g_j(x)$  在  $x^*$  可微,  
 $\nabla h_i(x^*)$ 、 $\nabla g_j(x^*)$  ( $j \in I(x^*)$ ) 线性无关, 则存在一组  
实数  $\mu_i$ 、 $\lambda_j$  满足

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^m \mu_i \nabla h_i(x^*) - \sum_{j=1}^l \lambda_j \nabla g_j(x^*) = 0 \\ \lambda_j g_j(x^*) = 0 \quad (j = 1, 2, \dots, l) \\ \lambda_j \geq 0 \quad (j = 1, 2, \dots, l) \end{cases}$$


上述为**K–T**条件, 满足该条件的可行点称为**K–T**点。

7、实例说明改进后的KT条件:

$$\left\{ \begin{array}{l} \min f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 2)^2 \\ s.t. \quad g_1(x) = x_1 + x_2 - 2 \leq 0 \\ \quad \quad g_2(x) = -x_1 \leq 0 \\ \quad \quad g_3(x) = -x_2 \leq 0 \\ \quad \quad h_1(x) = -x_1 + x_2 - 1 = 0 \end{array} \right.$$

定理1改进后表明: 若  $(x_1, x_2)^T$  是局部最优解, 则:

$$\left\{ \begin{array}{l} \nabla f(x^*) - \sum_{i \in I} \lambda_i^* \nabla g_i(x^*) - \sum_{j \in J} \mu_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, i \in I \\ \lambda_i^* \geq 0, i \in I \end{array} \right.$$



$$h_j(x^*) = 0, j \in J \quad \text{不要忘记这个}$$



$$\left\{ \begin{array}{l} \begin{pmatrix} 2(x_1-1) \\ 2(x_2-1) \end{pmatrix} + \lambda_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + \lambda_3 \begin{pmatrix} 0 \\ -1 \end{pmatrix} + \mu_1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \mathbf{0} \\ \lambda_1(x_1+x_2-2)=0 \\ \lambda_2(-x_1)=0 \\ \lambda_3(-x_2)=0 \\ \lambda_1, \lambda_2, \lambda_3 \geq 0 \\ h_1(x) = -x_1 + x_2 - 1 = 0 \end{array} \right.$$

互补松紧条件

**定理2** 对于

$$\begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i = 1, \dots, p \\ & h_j(x) = 0, \quad j = 1, \dots, q \end{cases}$$

1、 $f, g_i, h_j$  在  $x^*$  处连续可微

2、可行点在  $x^*$  处满足  $K-T$  条件,

3、 $f, g_i, i \in I(x^*)$  是凹函数,  $h_j$  是线性函数,

则  $x^*$  是  $MP$  问题的整体最优解

注：定理2表明，在凸性条件下，K-T点是整体最优解。

例：写出K-T条件；  
 求出相应的K-T点；  
 判断K-T点是不是问题的最优解

$$\left\{ \begin{array}{l} \min \quad f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 2)^2 \\ s.t. \quad g_1(x) = x_1 + x_2 - 2 \leq 0 \\ \quad \quad g_2(x) = -x_1 \leq 0 \\ \quad \quad g_3(x) = -x_2 \leq 0 \\ \quad \quad h_1(x) = -x_1 + x_2 - 1 = 0 \end{array} \right.$$

解：由于全部函数都是连续可微的，所以应用以下K-T条件

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i \in I} \lambda_i^* \nabla g_i(x^*) + \sum_{j \in J} \mu_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* g_i(x^*) = 0, i \in I \\ \lambda_i^* \geq 0, i \in I \end{array} \right.$$

➤首先写出原**MP**问题的**K-T**条件:

$$\left\{ \begin{array}{l} 2(x_1 - 1) + \lambda_1 - \lambda_2 - \mu_1 = 0 \\ 2(x_2 - 2) + \lambda_1 - \lambda_3 + \mu_1 = 0 \\ \lambda_1(x_1 + x_2 - 2) = 0 \\ \lambda_2 x_1 = 0 \\ \lambda_3 x_2 = 0 \\ \lambda_1, \lambda_2, \lambda_3 \geq 0 \end{array} \right. \quad \left. \vphantom{\begin{array}{l} 2(x_1 - 1) + \lambda_1 - \lambda_2 - \mu_1 = 0 \\ 2(x_2 - 2) + \lambda_1 - \lambda_3 + \mu_1 = 0 \\ \lambda_1(x_1 + x_2 - 2) = 0 \\ \lambda_2 x_1 = 0 \\ \lambda_3 x_2 = 0 \end{array}} \right\} \text{互补松紧条件}$$

➤根据定理1,**K-T**点还应该满足原问题的约束条件

$$\left\{ \begin{array}{l} x_1 + x_2 - 2 \leq 0 \\ -x_1 \leq 0, -x_2 \leq 0 \\ -x_1 + x_2 - 1 = 0 \end{array} \right.$$

➤利用互补松紧条件，可以求出**K-T**点：

$$\mathbf{x}^* = \left(\frac{1}{2}, \frac{3}{2}\right)^T$$

➤利用定理2，由于全部函数都连续可微，并且**f**和**g**都是凸函数，**h**是线性函数，所以**K-T**点就是整体最优解。

## 8.2 二次规划

$$\begin{aligned} \min \quad & \sum_{j=1}^n q_j x_j + \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n q_{jk} x_j x_k \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij} x_j = b_i, \quad i = 1, 2, \dots, m \quad (\text{i}) \\ & x_j \geq 0, \quad j = 1, 2, \dots, n \quad (\text{ii}) \end{aligned}$$

其中  $q_{jk} = q_{kj}$  .

Lagrange 函数

$$\begin{aligned} L(x, \mu, \lambda) = & \sum_{j=1}^n q_j x_j + \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n q_{jk} x_j x_k \\ & - \sum_{i=1}^m \mu_i \left( \sum_{j=1}^n a_{ij} x_j - b_i \right) - \sum_{j=1}^n \lambda_j x_j \end{aligned}$$

**K-T 条件**

$$\frac{\partial L}{\partial x_j} = q_j + \sum_{k=1}^n q_{jk} x_k - \sum_{i=1}^m a_{ij} \mu_i - \lambda_j = 0, \quad j = 1, \dots, n \quad (\text{iii})$$

$$\lambda_j x_j = 0, \quad j = 1, \dots, n, \quad (*)$$

$$\lambda_j \geq 0, \quad j = 1, \dots, n, \quad (\text{iv})$$

求二次规划的 K-T 点等价于求线性等式及不等式组 (i)、(ii)、(iii)、(iv) 的一个可行点，并且满足互补条件 (\*)。

设  $x^0$  是一个满足条件 (i)、(ii) 的基本可行解，则求 (i) - (iv) 的可行点可转化为线性规划问题：

$$\min \sum_{j=1}^n z_j$$

$$\sum_{k=1}^n q_{jk} x_k - \sum_{i=1}^m a_{ij} (\mu_i^+ - \mu_i^-) - \lambda_j + \delta_j z_j = -q_j, \quad j=1, \dots, n$$

$$\sum_{j=1}^n a_{ij} x_j = b_i, \quad i=1, \dots, m$$

$$x_j, \lambda_j, \mu_i^+, \mu_i^-, z_j \geq 0,$$

$$\text{其中 } \delta_j = \begin{cases} 1, & \sum_{k=1}^n q_{jk} x_k^0 \leq -q_j, \\ -1, & \sum_{k=1}^n q_{jk} x_k^0 > -q_j. \end{cases}$$

上述线性规划有初始基本可行解：

$$x_j = x_j^0, \lambda_j = 0, \mu_i^+ = \mu_i^- = 0, \quad z_j = \left| -q_j - \sum_{k=1}^n q_{jk} x_k^0 \right|$$

基变量包括  $x^0$  中的基变量和所有  $z_j$ 。



注：为了满足互补条件 (\*), 在用单纯形算法求解上述线性规划时，不能让  $x_j$  和  $\lambda_j$  同时成为基变量。

收敛性：若二次规划可行且  $(q_{jk})_{n \times n}$  正定，则

$$\min \sum_{j=1}^n z_j = 0, \text{ 即算法能获得整体最优解。}$$

若  $(q_{jk})_{n \times n}$  半正定，上述结论不一定成立，但可适当增大主对角元后化为正定阵处理。

## 可行方向法

$$\min f(x) \quad s.t. \quad g_i(x) \geq 0, \quad i = 1, \dots, m$$

在迭代点  $x^k$ ，选择一个可行下降方向  $p^k$  为搜索方向，则  $p^k$  应满足

$$\nabla f(x^k)^T p^k < 0$$

$$\nabla g_i(x^k)^T p^k > 0, \quad i \in I(x^k)$$

$p^k$  可以通过解下述线性规划获得：

$$\min \quad \eta$$

$$s.t. \quad \nabla f(x^k)^T p \leq \eta$$

$$\nabla g_i(x^k)^T p \geq -\eta, \quad i \in I(x^k)$$

$$-1 \leq p_j \leq 1, \quad j = 1, 2, \dots, n$$

$$\text{其中 } p = \begin{pmatrix} p_1 \\ \vdots \\ p_n \end{pmatrix}$$

$\eta = 0$ ,  $p = (0, \dots, 0)^T$  是上述线性规划的一个可行解。

性质：若  $\eta^* = 0$ , 则  $x^k$  处不存在可行下降方向,  $x^k$

已是  $K-T$  点 (若  $\nabla g_i(x^k)$  ( $i \in I(x^k)$ ) 线性无关);

若  $\eta^* < 0$ , 则得到  $x^k$  处的一个可行下降方向  $p^*$ 。

有例子表明上述方法不一定收敛到  $K-T$  点, 即总有  $\eta^* < 0$ 。

改进方法：在找可行下降方向时考虑所有约束, 即

$$\min \quad \eta$$

$$s.t. \quad \nabla f(x^k)^T p \leq \eta$$

$$g_i(x^k) + \nabla g_i(x^k)^T p \geq -\eta, \quad i = 1, 2, \dots, m$$

$$-1 \leq p_j \leq 1, \quad j = 1, 2, \dots, n$$

$\eta = 0$ ,  $p = (0, \dots, 0)^T$  也是上述线性规划的可 行解。

性质：若  $\eta^* = 0$ , 则  $x^k$  是  $K - T$  点；

若  $\eta^* < 0$ , 则  $p^*$  是  $x^k$  处的可行下降方向。

$$\because i \in I(x^k) \text{ 时, } g_i(x^k) = 0,$$

$$\therefore \nabla g_i(x^k)^T p^* \geq -\eta^* > 0,$$

$$\text{又 } \because \nabla f(x^k)^T p^* \leq \eta^* < 0, \quad \therefore p^* \text{ 是可行方向。}$$

可证：改进方法具有全局收敛性。

# 制约函数法

将约束非线性规划问题转化为一系列无约束问题求解。  
(SUMT: Sequential Unconstrained Minimization Technique)

## (1) 外点法

$$\begin{aligned} \min f(x) \quad s.t. \quad & h_i(x) = 0, \quad i = 1, \dots, m \\ & g_j(x) \geq 0, \quad j = 1, \dots, l \end{aligned}$$

记可行域为  $D$

出发点：构造一个无约束问题，使得  $x \in D$  时，对应的目标函数值为  $f(x)$ ； $x \notin D$  时，对应的目标函数值很大，因而不可能成为极小点。

构造罚函数  $p(x) = \begin{cases} 0, & x \in D \\ c, & x \notin D \end{cases}$

其中  $c$  是充分大的正数。

考虑无约束问题  $\min F(x) = f(x) + p(x)$

$F(x)$  称为增广目标函数，它的极小点也是原问题的极小点，但  $F(x)$  不能保持原目标函数  $f(x)$  可能具有的良好性态（如连续、光滑），因为  $F(x)$  在可行域  $D$  的边界上发生跳跃。

另构造罚函数

$$p_c(x) = c \sum_{i=1}^m h_i(x)^2 + c \sum_{j=1}^l (\min \{0, g_j(x)\})^2$$

性质：如果  $h_i(x)$  ( $i = 1, \dots, m$ ) 和  $g_j(x)$  ( $j = 1, \dots, l$ ) 连续（可导），则  $p_c(x)$  连续（可导）。


增广目标函数  $\min F_c(x) = f(x) + p_c(x)$   
 $c$  称为罚因子。

性质：设  $x^*(c)$  是  $\min F_c(x)$  的最优解，且  $x^*(c) \in D$ ，  
则  $x^*(c)$  也是  $\min_{x \in D} f(x)$  的最优解。

一般说来， $x^*(c) \in D$  仅在  $c$  足够大时才成立，但在实际计算中，过大的  $c$  会造成无约束问题  $\min F_c(x)$  求解困难，因此常取一系列递增的数  $\{c_k\}$ （趋于  $+\infty$ ），然后解一系列无约束问题  $\min F_{c_k}(x)$ 。

设  $f(x)$ 、 $h_i(x)$  ( $i = 1, \dots, m$ ) 和  $g_j(x)$  ( $j = 1, \dots, l$ ) 连续, 则  $x^*(c_k)$  从可行域  $D$  的外部趋向  $x^*$ , 因此称为外点法。

几何解释





例.  $\min (x_1)^2 + 2(x_2)^2 \quad s.t. \quad x_1 + x_2 - 1 \geq 0$

解.  $F_c(x) = (x_1)^2 + 2(x_2)^2 + c(\min\{0, x_1 + x_2 - 1\})^2$

$$= \begin{cases} (x_1)^2 + 2(x_2)^2 & x_1 + x_2 \geq 1 \\ (x_1)^2 + 2(x_2)^2 + c(x_1 + x_2 - 1)^2 & x_1 + x_2 < 1 \end{cases}$$

$$\frac{\partial F_c(x)}{\partial x_1} = \begin{cases} 2x_1 & x_1 + x_2 \geq 1 \\ 2x_1 + 2c(x_1 + x_2 - 1) & x_1 + x_2 < 1 \end{cases}$$

$$\frac{\partial F_c(x)}{\partial x_2} = \begin{cases} 4x_2 & x_1 + x_2 \geq 1 \\ 4x_2 + 2c(x_1 + x_2 - 1) & x_1 + x_2 < 1 \end{cases}$$

$$x_1 + x_2 \geq 1 \text{ 时, } \frac{\partial F_c(x)}{\partial x_1} = \frac{\partial F_c(x)}{\partial x_1} = 0 \text{ 无解;}$$

$$x_1 + x_2 < 1 \text{ 时, 由 } \frac{\partial F_c(x)}{\partial x_1} = \frac{\partial F_c(x)}{\partial x_1} = 0, \text{ 得}$$

$$\begin{cases} 2x_1 + 2c(x_1 + x_2 - 1) = 0 \\ 4x_2 + 2c(x_1 + x_2 - 1) = 0 \end{cases}$$

$$\therefore x_1 = \frac{2c}{2+3c}, \quad x_2 = \frac{c}{2+3c}$$

$$c \rightarrow +\infty \text{ 时, } x_1 \rightarrow \frac{2}{3}, \quad x_2 \rightarrow \frac{1}{3}$$

$$x^* = \left( \frac{2}{3}, \frac{1}{3} \right).$$


## (2) 内点法

可行域  $D = \text{int } D \cup \partial D$

内部

$$\text{int } D = \{x \mid g_j(x) < 0, \forall j\}$$

边界  $\partial D = \{x \mid \text{至少有一个 } j \text{ 使得 } g_j(x) = 0\}$



内点法的迭代点列在可行域的内部移动，并对接近可行域边界的点施加越来越大的惩罚，对可行域边界上的点施加无限大的惩罚，这好比在边界上筑一道墙阻止迭代点穿越边界。

内点法要求可行域的内点集合非空，并且要求初始点必须是内点，因此内点法只能处理不等式约束。

$$\min f(x) \quad s.t. \quad g_i(x) \geq 0, \quad i = 1, \dots, m$$

$$\text{设 } B_c(x) = c \sum_{i=1}^m \frac{1}{g_i(x)} \quad \text{或} \quad B_c(x) = -c \sum_{i=1}^m \ln g_i(x)$$

$$\text{考虑无约束问题} \quad \min F_c(x) = f(x) + B_c(x)$$

当  $x$  从可行域的内部趋向边界时,  $B_c(x)$  无限增大, 因此  $F_c(x)$  的极小点将落在原问题可行域的内部。

另一方面, 由于原问题的目标是  $\min f(x)$ , 因此必须尽可能减弱  $B_c(x)$  的影响, 为此设置一系列单调递减趋于零的罚参数  $\{c_k\}$ , 然后解一系列无约束问题  $\min F_{c_k}(x) = f(x) + B_{c_k}(x)$ 。

收敛性: 若  $f(x)$ 、 $g_i(x) (i = 1, \dots, m)$  连续, 则内点法产生的点列  $x^*(c_k)$  收敛于  $x^*$ 。

例.  $\min 2x_1 + 3x_2 \quad s.t. \quad 1 - 2(x_1)^2 - (x_2)^2 \geq 0$

解.  $F_c(x) = 2x_1 + 3x_2 - c \ln \left( 1 - 2(x_1)^2 - (x_2)^2 \right)$

由  $\frac{\partial F_c(x)}{\partial x_1} = 2 + \frac{4cx_1}{1 - 2(x_1)^2 - (x_2)^2} = 0,$

$\frac{\partial F_c(x)}{\partial x_2} = 3 + \frac{2cx_2}{1 - 2(x_1)^2 - (x_2)^2} = 0,$  得

$$x_1 = \frac{c - \sqrt{c^2 + 11}}{11}, \quad x_2 = \frac{3c - 3\sqrt{c^2 + 11}}{11}$$

$$c \rightarrow 0 \text{ 时}, \quad x_1 \rightarrow -\frac{1}{\sqrt{11}}, \quad x_2 \rightarrow -\frac{3}{\sqrt{11}}$$

$$x^* = \left( -\frac{1}{\sqrt{11}}, -\frac{3}{\sqrt{11}} \right).$$